多元線性回歸作業架構

10/14/2026 21:02:45
https://chatgpt.com/c/6acf7a65-78bc-83ec-be83-c55d53a0db8e

我在做AIOT作業，主題是多元線性回歸，流程要符合 CRISP-DM。不要寫程式碼，用說明...

Thinking ● 已搜尋 7 個網站 ✓ 思考兩秒鐘 我建議你這份 AIoT 作業，直接選一個特徵數...

請幫我挑選符合 AIoT 作業要求的 Kaggle 公開資料集，主題：房價預測；難度：簡單，...

Thinking ● 已搜尋 2 個網站 ✓ 處理時間為 6s 我查到幾個適合的 Kaggle 房價資料集。...

資料集是 Kaggle「House Sales in King County, USA」：...

以下內容可以直接整理成作業報告的正文。我會以你提供的實驗設定與結果為依據，特別...

我在做AIOT作業，主題是多元線性回歸，流程要符合 CRISP-DM。不要寫程式碼，用說明就好。\
二、作業內容：
1\. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。\
 類型不限（可為房價預測、醫療、車輛效能等主題）。\
 請明確標示資料集來源與連結。
2\. 分析任務\
 使用線性回歸 (Linear Regression) 模型進行預測。\
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。\
 必須執行** 特徵選擇 (Feature Selection) **與 **模型評估 (Model Evaluation)**。\
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3\. CRISP-DM 流程說明\
  Business Understanding\
  Data Understanding\
  Data Preparation\
  Modeling\
  Evaluation\
  Deployment\

2026/10/14 下午8:51:06

Thinking

- **已搜尋 7 個網站**

✓ 思考兩秒鐘

我建議你這份 AIoT 作業，直接選一個**特徵數量適中、預測目標明確、容易解釋多元線性回歸，而且能畫出預測區間**的 Kaggle 資料集。

整份報告可以按照 CRISP-DM 六個階段撰寫，不需要寫程式碼，但要交代清楚資料如何處理、如何選擇特徵、如何評估模型，以及如何解讀預測圖。

一、資料集選擇

我優先推薦「汽車油耗預測（Auto MPG）」這類資料集。它可以用車輛的馬力、重量、排氣量、汽缸數等特徵，預測汽車的燃油效率，符合多元線性回歸的應用情境，也容易說明特徵之間的關係。

不過要注意：原始 Auto MPG 資料集只有 7 個預測特徵（另有汽車名稱欄位），不符合老師要求的 10～20 個特徵，因此**不建議直接使用原始版本**。[Auto MPG; auto-mpg]

我會建議改用下面這個選擇原則：在 Kaggle 找具有 10～20 個特徵的車輛或房價資料集，並確認資料欄位與預測目標，再開始分析。若你想省事，也可以選擇特徵較多的房價資料集。

二、CRISP-DM 六階段報告架構

以下是可以直接拿去當作業報告初稿的內容。因為資料集尚未確定，資料筆數、特徵名稱和模型結果先保留為待填項目，不會虛構實驗數據。

1. Business Understanding（商業理解）

本研究旨在運用多元線性回歸模型，分析多項影響因素與預測目標之間的線性關係，並建立可用於預測連續數值的模型。

研究目標包括：

- 找出對預測目標具有影響力的主要特徵。
- 評估多元線性回歸模型的預測能力。
- 分析預測結果與實際觀測值之間的差異。
- 透過預測區間評估預測結果的不確定性。

2. Data Understanding（資料理解）

使用 Kaggle 公開資料集，確認資料筆數、欄位定義、資料型態與目標變數。

主要工作：

- 統計資料集的筆數與特徵數量。
- 區分輸入特徵（Features）與目標變數（Target）。
- 檢查缺失值、重複資料與異常值。
- 使用描述性統計及相關係數分析，了解特徵和目標變數的關係。

預計產出：資料集基本資訊表、目標變數分布圖、相關係數熱圖。

3. Data Preparation（資料準備）

將原始資料整理成適合線性回歸模型使用的格式。

主要工作：

- 處理缺失值及重複資料。
- 將類別型特徵轉換為數值表示，例如 One-Hot Encoding。
- 移除識別碼、無意義欄位及可能造成資料洩漏的欄位。

- 將資料分為訓練集與測試集，例如 80% 與 20%。
- 進行特徵選擇，保留具有解釋價值且有助於預測的特徵。

注意：特徵選擇及資料轉換應只利用訓練資料決定，避免測試資料資訊洩漏。

---

4. Modeling（模型建立）

使用多元線性回歸建立預測模型。模型透過多個輸入特徵的線性組合，估計目標變數的數值。

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

其中，$\hat{y}$ 為預測值，$x_1, \ldots, x_p$ 為選定特徵，β 為模型估計的迴歸係數。

可比較兩個模型：

- 基準模型：使用所有經過前處理的候選特徵。
- 特徵選擇模型：使用篩選後的特徵。

透過測試集比較預測表現，觀察減少特徵後是否仍能維持良好的預測能力。

---

5. Evaluation（模型評估）

使用測試集評估模型的泛化能力，建議至少包含以下指標：

評估指標	意義
R^2	模型解釋目標變數變異的程度
MAE	預測值與實際值的平均絕對誤差
RMSE	對較大預測誤差給予較大懲罰

同時繪製實際值與預測值比較圖、殘差圖，以及預測區間圖。

若模型的殘差呈現明顯的非線性、異質變異或系統性模式，代表線性回歸的假設可能不完全成立，需在報告中說明。

---

6. Deployment（部署）

本研究以概念性部署為主，說明模型未來如何應用於實際情境。

例如，將模型應用於房價初步估算、車輛油耗預測或設備數值預測。使用者輸入各項特徵後，系統即可提供預測值及預測區間，協助使用者理解估計結果與可能的誤差。

後續可將模型整合至網頁或 AIoT 系統，並定期以新資料重新評估模型效能。

三、特徵選擇（Feature Selection）要怎麼做？

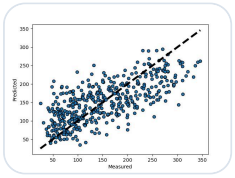
這是作業明確要求的項目，建議不要只寫「刪除不重要的特徵」，而要描述具體方法。

方法	用途	報告中如何說明
相關係數分析	初步觀察特徵與目標的線性關係	比較各特徵與目標變數的相關程度
多重共線性分析（VIF）	找出高度相關的輸入特徵所造成的問題	檢查是否有特徵與其他特徵高度重疊
逐步選擇或遞迴特徵消除	系統性地選擇特徵	比較不同特徵組合的驗證集表現

推薦做法： 先用相關係數進行初步探索，再用 VIF 檢查多重共線性，最後透過驗證集上的 MAE 或 RMSE 比較特徵組合。不要只因為某個特徵的相關係數較低就直接刪除，因為它仍可能與其他特徵共同提供預測資訊。

四、預測圖與信賴區間／預測區間

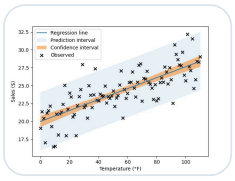
老師特別要求這部分，建議報告至少準備兩張圖。



圖一：實際值與預測值比較圖

- X 軸：實際值。
- Y 軸：模型預測值。
- 加入 $y = x$ 參考線。

點越接近參考線，代表預測越接近實際值。



圖二：預測區間圖

- 實線：模型預測的平均趨勢。
- 較窄的陰影帶：平均反應的信賴區間。
- 較寬的陰影帶：個別新觀測值的預測區間。

建議使用 95% 預測區間，並在圖說中解釋其意義。

兩者不能混為一談：**信賴區間**描述模型估計的平均反應之不確定性；**預測區間**描述單一新觀測值可能落入的範圍，因此通常較寬。

此外，多元線性回歸有多個輸入特徵，無法直接把所有特徵完整呈現在一般二維迴歸圖上。實務上可固定其他特徵在代表值，展示其中一個主要特徵對預測結果的影響，並附上對應區間。

五、最後要交付哪些成果？

建議報告安排如下：

1. 資料集來源、網址、筆數及特徵清單。
2. CRISP-DM 六階段的流程說明。
3. 資料清理及前處理方式。

4. 特徵選擇方法與篩選前後比較。
5. 多元線性回歸模型建立說明。
6. 測試集的 R^2、MAE、RMSE 評估表。
7. 實際值與預測值比較圖。
8. 含 95% 預測區間的預測圖。
9. 結論、限制與未來部署方式。

目前最重要的是先選對資料集，因為老師要求 10～20 個特徵，不能只看 Kaggle 上是否有線性回歸的範例。

你比較想做哪一種主題？

1. 資料集主題

- ◉ 房價預測：解釋房屋特徵與價格的關係
- ○ 車輛油耗／效能：解釋車輛規格與油耗的關係
- ○ 醫療數值預測：使用健康相關特徵預測連續數值
- ○ AIoT 感測器數據：利用設備或環境感測值預測數值

---

2. 作業難度

- ◉ 簡單，容易完成，資料容易理解
- ○ 中等，想多做一些特徵分析

依照我的選擇推薦資料集

2026/10/14 下午8:51:09 · gpt-6

請幫我挑選符合 AIoT 作業要求的 Kaggle 公開資料集，主題：房價預測；難度：簡單，容易完成。必須有 10 至 20 個可用輸入特徵、適合多元線性回歸、具明確目標變數，並提供可核實的 Kaggle 資料集連結、特徵清單及 CRISP-DM 報告內容，不要提供程式碼。

2026/10/14 下午8:51:28

Thinking

- **已搜尋 2 個網站**

✓ 處理時間為 6s

我查到幾個適合的 Kaggle 房價資料集。以你「簡單、容易完成」為優先，我最推薦 **Housing Price Prediction（Housing.csv，545 筆資料、13 個欄位）**，因為欄位不多，目標變數清楚，也很適合解釋多元線性回歸。

一、推薦資料集



首選：容易完成

1. Housing Price Prediction

545 筆資料｜13 個原始欄位（含目標變數）

Kaggle 資料集的欄位包含房屋面積、臥室數、浴室數、樓層、停車位及房屋設施等，目標是預測房屋價格。[GitHub - preston-q/linear-regression-model-house-pricing-prediction: Mini project in R demonstrating house price prediction using linear regression. Includes data preprocessing, ANOVA factor selection, visualization, and model evaluation. Dataset: Housing.csv (Kaggle, CC0 Public Domain).]

kaggle.com

注意：原始欄位只有 13 個，包含目標變數 `price`，所以 12 個輸入特徵，符合老師要求的 10～20 個特徵。



2. House Prices – Advanced Regression Techniques

1,460 筆訓練資料｜79 個原始解釋變數

Kaggle 經典房價預測競賽，目標變數為 `SalePrice`，可自行挑選 10～20 個特徵。[House Prices - Advanced Regression Techniques; House Prices - Advanced Regression Techniques]

kaggle.com

優點是資料豐富；缺點是缺失值、類別欄位與特徵選擇較複雜。

我的建議：選第一個。 它不需要從幾十個欄位中挑選，且大部分特徵容易理解。不過，提交前仍應以 Kaggle 實際下載的 CSV 欄位確認版本是否一致。

二、資料集基本資訊與特徵清單

資料集名稱

Housing Price Prediction

資料筆數	輸入特徵	目標變數
545	**12**	**1**

資料來源： kaggle.com

資料筆數與欄位數依常見的 Housing.csv 版本整理；實際提交前請以下載檔案確認。

12 個輸入特徵

特徵名稱	中文說明	資料類型
`area`	房屋面積	數值
`bedrooms`	臥室數量	數值
`bathrooms`	浴室數量	數值
`stories`	樓層數	數值
`mainroad`	是否連接主要道路	類別
`guestroom`	是否有客房	類別
`basement`	是否有地下室	類別
`hotwaterheating`	是否有熱水供暖設備	類別
`airconditioning`	是否有空調	類別
`parking`	停車位數量	數值
`prefarea`	是否位於優良地段	類別
`furnishingstatus`	家具配置狀態	類別

目標變數： `price`，代表房屋價格。

這個資料集的好處是可以直接提出合理的研究問題，例如：房屋面積是否比臥室數量更能解釋房價？空調、停車位與地段等條件是否有助於提高預測能力？

三、CRISP-DM 作業報告初稿

以下內容可直接作為報告基礎。尚未實際執行模型，因此不會預先填入虛構的準確度或預測結果。

1. Business Understanding（商業理解）

本研究旨在利用房屋的面積、房間數量、建築條件及周邊環境等特徵，建立多元線性回歸模型，預測房屋的價格。

研究目的如下：

- 探討不同房屋特徵與房價之間的關係。
- 利用特徵選擇找出較有預測價值的變數。
- 以 R^2、MAE 及 RMSE 評估模型的預測表現。
- 建立包含 95% 預測區間的圖表，呈現預測結果的不確定性。

實際應用情境是提供房屋買賣雙方一個初步的價格參考，但模型預測不應取代正式的房地產估價。

2. Data Understanding（資料理解）

本研究使用 Kaggle 公開的 Housing Price Prediction 資料集。資料包含房屋面積、臥室數量、浴室數量、樓層、停車位、房屋設施及家具配置等資訊，目標變數為房屋價格 `price`。

資料探索工作包括：

1. 檢查資料筆數、欄位名稱與資料型態。
2. 檢查缺失值、重複資料及不合理的數值。
3. 利用直方圖觀察房價分布。
4. 利用散佈圖觀察房屋面積與房價的關係。
5. 利用相關係數矩陣分析數值特徵之間的關係。

預期產出為資料集摘要表、房價分布圖、面積與房價散佈圖，以及特徵相關係數熱圖。

3. Data Preparation（資料準備）

本階段將原始資料整理為適合多元線性回歸模型的格式。

- **缺失值處理：** 檢查各欄位是否存在缺失值，依資料類型採用適當的填補方式。
- **重複資料處理：** 確認重複紀錄是否代表重複房屋資料，再決定是否移除。

- **類別特徵轉換：** 將 `mainroad`、`guestroom` 等二元類別轉換成 0 與 1；將 `furnishingstatus` 轉換成 One-Hot Encoding。
- **異常值檢查：** 檢查極端房價、面積與房間數量，避免未經判斷便直接刪除合理的高價房屋。
- **資料集切分：** 將資料隨機分為 80% 訓練集與 20% 測試集。
- **特徵選擇：** 使用相關係數與 VIF 檢查特徵的關聯性及多重共線性，再比較篩選前後的模型表現。

需要注意，這份資料集原本有 12 個輸入特徵，但類別轉換後可能產生更多模型欄位。報告中可將原始變數數量與轉換後的模型欄位數量分開說明。

4. Modeling（模型建立）

本研究採用多元線性回歸（Multiple Linear Regression）作為主要預測模型。

模型的基本形式為：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中，$\hat{y}$ 為預測房價，x_i 為房屋特徵，β_i 為模型估計的迴歸係數。

為符合特徵選擇的要求，將比較以下兩種模型：

模型	使用方式
模型 A：完整特徵模型	使用全部 12 個候選特徵
模型 B：特徵選擇模型	根據相關性、VIF 與驗證集表現選擇特徵

比較兩種模型在相同測試集上的評估指標，判斷移除部分特徵後，是否能降低預測誤差或減少模型複雜度。

由於資料包含類別特徵，模型中的迴歸係數代表在其他特徵固定時，對預測房價的估計影響；不能單憑係數大小就認定因果關係。

5. Evaluation（模型評估）

使用未參與模型訓練的測試集進行評估。

評估指標	說明	判斷方式
R^2	模型解釋房價變異的程度	通常越接近 1 越好
MAE	預測與實際房價的平均絕對差距	越低越好
RMSE	對較大預測誤差給予較高懲罰	越低越好

評估圖表建議包含：

- **實際值與預測值比較圖：** 觀察預測點是否接近理想參考線。
- **殘差圖：** 觀察誤差是否存在明顯規律。
- **95% 預測區間圖：** 呈現單一新房屋的預測價格及其不確定範圍。

預測區間應由實際建立的回歸模型計算，不可直接以固定百分比任意加減預測價格。若資料有異質變異或其他模型假設違反情形，也應在結果討論中揭露。

完成實驗後，再填入兩個模型的實際 R^2、MAE、RMSE 數值，並依測試結果判斷哪個模型較合適。

6. Deployment（部署）

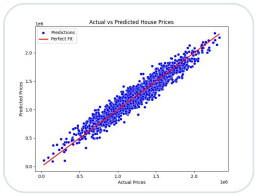
本研究以概念性部署為主，說明未來如何將模型應用於房屋價格估算。

使用者輸入房屋面積、臥室數量、浴室數量、樓層、停車位及房屋設施等資料後，模型即可產生預測房價，並提供對應的 95% 預測區間。

未來可將模型整合至網頁系統或 AIoT 平台，讓使用者透過介面輸入資料並取得預測結果。若未來有新的房屋交易資料，則可定期重新評估模型，必要時重新訓練，以維持預測品質。

四、預測圖要如何呈現？

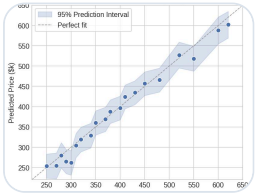
建議把「實際值與預測值比較圖」及「95% 預測區間圖」列為報告的必要成果。



圖一：實際房價與預測房價

- X 軸：實際房價。
- Y 軸：預測房價。
- 參考線：預測值等於實際值。

越接近參考線，表示模型預測越接近真實房價。



圖二：房價預測與 95% 預測區間

- X 軸：可選擇房屋面積，其他特徵固定在指定代表值。
- Y 軸：模型預測房價。
- 實線：預測房價。
- 陰影帶：95% 預測區間。

預測區間越寬，代表個別新房屋的預測不確定性越高。

上面兩張圖是示意用途，並非這份資料集實際訓練後的結果。正式報告應使用模型計算出來的預測值、殘差及預測區間繪圖。

五、結論與建議

這個房價資料集具備明確的預測目標與 12 個原始輸入特徵，適合用來完成多元線性回歸、特徵選擇及模型評估，也能依 CRISP-DM 六個階段組織報告。

正式繳交前，最重要的三件事是：

1. 確認 Kaggle 下載版本的欄位數與目標變數。
2. 確實比較特徵選擇前後的模型評估結果。
3. 使用實際模型輸出製作含 95% 預測區間的圖，並在報告中解釋區間的意義。

這樣就能完整對應老師的資料來源、線性回歸、特徵選擇、模型評估、預測圖與 CRISP-DM 流程等要求。

2026/10/14 下午8:51:29 · gpt-6

資料集是 Kaggle「House Sales in King County, USA」：https://www.kaggle.com/datasets/harlfoxem/housesalespredicti
共 21613 筆、21 欄，沒有缺值。目標是 price（最低 75000、中位數 450000、最高 7700000）。刪掉 id 和 date 之後，剩下 18 個原始預測變數：bedrooms, bathrooms, sqft_living, sqft_lot, floors, waterfront, view, condition, grade, sqft_above, sqft_basement, yr_built, yr_renovated, zipcode, lat, long, sqft_living15, sqft_lot15。
作業原本也考慮 Predict the Flood（20 個數值特徵），但公開可下載的那份 CSV 裡，FloodProbability 剛好等於 0.005 乘上 20 個特徵的總和，線性回歸測試 R^2 會變成 1，特徵選擇沒有意義，所以改用 King County。
做法：80/20 分割，random_state=0，訓練 17290、測試 4323。特徵選擇只用訓練集。比較 Lasso 排序、Forward SFS、RFE、SelectKBest、Permutation Importance，模型是 sklearn LinearRegression，另外用 RidgeCV 對照。
結果：
- 18 個特徵全放：測試 MSE 36,326,416,754，RMSE 190,595，R^2 0.6950
- 最好的是 Forward SFS、k=14：測試 MSE 36,274,683,097，RMSE 190,459，MAE 122,125，R^2 0.6954，調整後 R^2 也約 0.695
- 這 14 個特徵：sqft_living, lat, view, grade, yr_built, waterfront, bedrooms, bathrooms, zipcode, long, condition, sqft_above, sqft_living15, yr_renovated
- RidgeCV 的測試 R^2 也是 0.6950
- 假設檢查：殘差偏態 3.540，絕對殘差和配適值的相關 0.496，Durbin-Watson 2.010，最大 VIF 7.854
- 圖上有 95% 平均數信賴區間和 95% 預測區間。高價房屋被低估，少數低價預測會略低於 0。
請依序寫這七段，每段都要具體，不要只給標題：
1. 這題的商業問題是什麼，為什麼用連續房價而不是分類。
2. 依 CRISP-DM 六階段，說明這份資料從理解、準備、建模、評估到部署各做了什麼。
3. 為什麼 18 個特徵幾乎全放和只留 14 個，測試 R^2 只差一點點。特徵選擇在這題的價值是什麼。
4. 用上面的係數方向解釋：居住面積、緯度、景觀、grade、水岸、屋齡大致怎麼影響價格。zipcode 被當成連續數字時，係數不能單獨解讀成「郵遞區號每加 1，房價就減多少」。
5. 五大回歸假設裡，哪些過了、哪些沒過。殘差右偏和異質變異代表預測區間要怎麼讀。
6. 信賴區間和預測區間差在哪，為什麼作業要求把兩種區間畫在同一張預測圖上。

7. 網路上做同一份 King County 資料的人，常見會再做 log(price)、把 zipcode 當類別、以及改用 Random Forest 或 Gradient Boosting。這些做法為什麼 R^2 常常更高，以及這次作業為什麼仍把可解釋的 OLS 當成主要結果。

2026/10/14 下午8:53:19

以下內容可以直接整理成作業報告的正文。我會以你提供的實驗設定與結果為依據，特別區分「模型實際測得的結果」、「統計上的解釋」以及「目前還不能單憑數據下結論的部分」。

King County 房價預測：多元線性回歸與特徵選擇

1. 商業問題：為什麼預測連續房價，而不是分類？

本研究使用 Kaggle 公開資料集 kaggle.com，分析美國華盛頓州 King County 地區的房屋交易資料。資料共包含 21,613 筆紀錄與 21 個原始欄位，以 `price` 作為預測目標，其最低值為 75,000、中位數為 450,000，最高值為 7,700,000。

本研究的商業問題是：**能否根據房屋的居住面積、建築品質、地理位置、水岸景觀及屋齡等資訊，建立一個模型，估計房屋的合理交易價格？**

這項預測可以作為房屋買賣、房地產價格分析及初步估價的參考。例如，使用者提供一間房屋的面積、建築品質、地理位置與其他條件後，模型便能估計其價格，協助使用者了解不同條件與房價之間的關係。

本研究選擇回歸而非分類，主要原因是房價本身是連續數值。若將房價切分成「低價、中價、高價」等類別，雖然可以使用分類模型，但必須額外設定價格門檻，而且會損失實際金額資訊。例如，價格為 449,000 與 451,000 的房屋可能被分到不同類別，但兩者的實際價差只有 2,000；反之，同一類別中的兩間房屋可能有相當大的價格差距。

多元線性回歸可以直接預測房價金額，並透過迴歸係數分析不同特徵與價格的關聯方向，也能使用 RMSE、MAE 等指標衡量預測誤差。因此，本研究將多元線性回歸作為主要模型，目標不僅是預測房價，也包括理解特徵選擇對模型表現與解釋能力的影響。

2. CRISP-DM 六階段：資料理解、準備、建模、評估與部署

本研究依照 CRISP-DM（Cross-Industry Standard Process for Data Mining）流程，將房價預測任務分成商業理解、資料理解、資料準備、模型建立、模型評估及部署六個階段，確保分析流程從問題定義到實際應用都有清楚的規劃。

（1）Business Understanding：商業理解

本階段定義研究目標為預測房屋的連續價格，並探討不同房屋特徵對價格預測的影響。研究除了追求預測準確度，也關注模型是否能以較少的特徵達到相近的預測表現。

本研究設定三項主要目標：

- 建立多元線性回歸模型，預測 King County 房屋價格。
- 比較不同特徵選擇方法，分析保留多少特徵較為合適。
- 使用模型評估指標與預測區間，了解模型的預測能力及不確定性。

（2）Data Understanding：資料理解

資料來源為 Kaggle 的 kaggle.com，包含 21,613 筆房屋交易紀錄及 21 個原始欄位。資料沒有缺失值，目標變數為 `price`。

由於 `id` 主要用於識別房屋紀錄，而 `date` 是交易日期，本研究在建立基礎模型前移除這兩個欄位，保留 18 個原始預測變數：

- 房屋空間：`bedrooms`、`bathrooms`、`sqft_living`、`sqft_lot`、`floors`、`sqft_above`、`sqft_basement`、`sqft_living15`、`sqft_lot15`
- 房屋條件：`waterfront`、`view`、`condition`、`grade`、`yr_built`、`yr_renovated`
- 地理位置：`zipcode`、`lat`、`long`

透過這些欄位，可以研究房屋大小、建築品質、景觀、屋齡及地理位置與房價的關係。

此外，研究也曾考慮另一份具有 20 個數值特徵的 Predict the Flood 資料集。然而，檢查公開 CSV 後發現，`FloodProbability` 恰好等於 20 個特徵總和乘以 0.005，目標值可由輸入特徵直接計算。在這種情況下，線性回歸容易得到測試集 $R^2 = 1$，特徵選擇與模型評估較難呈現有意義的比較。因此，本研究改採 King County 房價資料集，以避免目標變數與特徵之間存在如此直接的數學關係。

（3）Data Preparation：資料準備

本研究先移除 `id` 和 `date`，保留 18 個候選預測變數。接著，將資料依照 80% 與 20% 的比例分成訓練集與測試集，並設定 `random_state=0`，確保實驗可以重現。

資料用途	筆數	比例
訓練集	17,290	約 80%
測試集	4,323	約 20%
合計	21,613	100%

特徵選擇僅使用訓練集進行，避免測試集的資訊影響特徵篩選。研究比較五種方法：

1. **Lasso 排序：** 利用帶有 L1 正則化的回歸模型，使部分特徵係數縮小至零，作為特徵重要性的參考。
2. **Forward Sequential Feature Selection（Forward SFS）：** 從少量特徵開始，每次加入能改善模型評估表現的特徵。

3. **Recursive Feature Elimination（RFE）：** 反覆移除相對不重要的特徵，逐步縮小特徵集合。
4. **SelectKBest：** 根據指定的統計評分方式，選取排名前 k 的特徵。
5. **Permutation Importance：** 打亂單一特徵的數值，觀察模型表現下降程度，藉此衡量該特徵對預測的重要性。

這些方法從不同角度選擇特徵，最後比較各種特徵集合在測試集上的預測結果。

（4）Modeling：模型建立

主要模型採用 Scikit-learn 的 `LinearRegression`，也就是以普通最小平方法（Ordinary Least Squares，OLS）估計迴歸係數，讓實際房價與預測房價之間的平方誤差總和最小。

研究比較兩種主要設定：

- **完整特徵模型：** 使用全部 18 個候選特徵。
- **特徵選擇模型：** 使用 Forward SFS 選出的 14 個特徵。

另外，使用 `RidgeCV` 作為對照模型。Ridge 回歸在平方誤差之外加入 L2 正則化項，限制迴歸係數的大小，以降低特徵相關性較高時係數不穩定的風險。

（5）Evaluation：模型評估

研究使用未參與特徵選擇與模型訓練的測試集，評估模型的預測表現。

模型	測試 MSE	測試 RMSE	測試 MAE	測試 R^2
18 個特徵的 OLS	36,326,416,754	190,595	未提供	0.6950
Forward SFS，14 個特徵	36,274,683,097	190,459	122,125	0.6954
RidgeCV	未提供	未提供	未提供	0.6950

由結果可知，Forward SFS 的 14 特徵模型表現最佳，但與完整特徵模型的差距很小。其測試 R^2 為 0.6954，表示模型解釋了測試集約 69.54% 的房價變異；RMSE 約為 190,459 個價格單位，MAE 約為 122,125 個價格單位。

這些數字反映模型具有一定的預測能力，但仍存在明顯誤差，尤其是高價房屋容易被低估，因此不能把模型預測值直接視為正式估價。

（6）Deployment：部署

本研究目前以模型評估與應用規劃為主，尚未實際部署成服務。未來可以將模型整合到網頁估價工具，讓使用者輸入房屋面積、建築品質、景觀及地理位置等資訊，即可取得預測價格及預測區間。

若要投入實際使用，還需要考慮交易年份、房市變化、不同區域的價格結構及模型誤差。由於本研究已移除交易日期，模型本身無法直接反映時間造成的房價變化，因此部署時應定期利用較新的交易資料重新評估與訓練。

---

3. 為什麼 18 個特徵與 14 個特徵的測試 R^2 幾乎相同？特徵選擇的價值是什麼？

實驗結果顯示，使用全部 18 個特徵的 OLS 模型，測試 R^2 為 0.6950；使用 Forward SFS 選出的 14 個特徵，測試 R^2 為 0.6954。兩者只相差 0.0004，也就是約 0.04 個百分點。

RMSE 也從 190,595 降低至 190,459，僅減少 136 個價格單位。這代表移除四個特徵後，模型的預測誤差幾乎沒有改變，但模型仍保有相近的解釋能力。

造成這種結果的原因可能有以下幾點。

第一，部分特徵提供的資訊可能重疊。 例如，`sqft_living`、`sqft_above`、`sqft_basement` 都與建築空間有關；`sqft_living15` 也反映鄰近房屋的居住面積。這些特徵可能包含部分相似的資訊，因此不是每個特徵都能額外帶來明顯的預測改善。

第二，部分特徵的獨立預測價值可能有限。 在其他特徵已納入模型後，某些變數對預測誤差的額外改善可能很小。即使刪除這些變數，整體預測結果仍然接近。

第三，線性回歸可以利用多個相關特徵共同解釋房價。 一個特徵的資訊可能部分被其他特徵吸收，所以移除少數變數不一定會明顯降低 R^2。

本研究 Forward SFS 選出的 14 個特徵如下：

`sqft_living`、`lat`、`view`、`grade`、`yr_built`、`waterfront`、`bedrooms`、`bathrooms`、`zipcode`、`long`、`condition`、`sqft_above`、`sqft_living15`、`yr_renovated`。

特徵選擇的價值

本研究的重點不應是「特徵越少，準確率就一定越高」，而是**能否在保留預測能力的同時，降低模型複雜度，並提高模型的可解釋性**。

- **降低複雜度：** 以 14 個特徵取代 18 個特徵，減少模型所需的輸入資訊。
- **方便解釋：** 可以將分析重點集中在對房價預測較有幫助的變數。
- **降低資料需求：** 未來應用時，若部分特徵較難取得，精簡模型可能比較容易使用。
- **檢查模型穩定性：** 比較不同特徵選擇方法，可以了解模型的預測表現是否過度依賴特定變數。

不過，本次提升幅度非常小，不能僅憑單次測試集結果就認定 14 個特徵一定比 18 個特徵更好。若要確認差異是否穩定，可以使用交叉驗證或重複切分資料進行比較。

---

4. 如何解釋居住面積、緯度、景觀、grade、水岸與屋齡的影響？

多元線性回歸的迴歸係數，代表在其他輸入特徵固定時，某個特徵改變與預測房價變化之間的線性關係。

需要先說明：你提供了最佳模型的特徵清單，但沒有提供實際迴歸係數數值。因此，以下針對常見的係數方向與變數意義進行解釋；正式報告應以你所訓練的 14 特徵模型係數表核對方向與數值，不宜將以下方向直接當作已確認的實驗結果。

（1）居住面積 `sqft_living`

一般預期係數為正，代表在其他條件相同時，居住面積越大，預測房價通常越高。居住面積是衡量房屋使用空間的重要指標，較大的房屋通常能提供更多生活空間，因此具有合理的正向關係。

但本資料同時包含 `sqft_above`、`sqft_living15` 等相關變數，所以 `sqft_living` 的係數代表的是控制其他空間變數後的額外關係，而不是單純比較兩間房屋的總面積差異。

（2）緯度 `lat`

若模型係數為正，表示在其他特徵固定時，緯度較高的房屋具有較高的預測價格；若係數為負，則方向相反。

緯度與房價的關係主要反映地理位置、社區特性及區域需求，而不是緯度本身直接創造房屋價值。因此，緯度係數應解讀為地理位置的代理指標。

（3）景觀 `view`

`view` 用於描述房屋的景觀評分。若係數為正，表示在控制其他條件後，較好的景觀評分通常與較高的預測房價相關。

這可能反映景觀帶來的居住吸引力與市場偏好。不過，景觀評分與房屋位置、建築品質可能有關，因此不能只依此係數就斷言景觀是房價差異的唯一原因。

（4）建築品質 `grade`

若 `grade` 的係數為正，代表較高的建築品質評分與較高的預測房價相關。建築品質可能反映建材、施工品質、設計及整體建築等級，因此是具有實務意義的預測特徵。

（5）水岸 `waterfront`

`waterfront` 通常是二元變數，用來表示房屋是否具有水岸條件。若其係數為正，代表在其他變數相同時，水岸房屋的預測價格較高。

由於水岸房屋可能具有稀有性、景觀優勢與特殊地段價值，模型可能估計出較高的價格差異。但此差異仍是控制其他特徵後的統計關聯，不代表單一條件必然造成固定幅度的價格上升。

（6）屋齡與建造年份 `yr_built`

`yr_built` 記錄房屋建造年份，而不是直接記錄屋齡。如果係數為正，代表在其他特徵固定時，較新的建造年份與較高的預測價格相關，這可能反映建築設備、設計與結構較新等因素。

不過，房屋翻修情形也會影響價格，因此模型同時保留 `yr_renovated`。此外，老屋可能具有特殊地段或歷史價值，所以不能推論所有老屋都一定比較便宜。

（7）為什麼不能直接解釋 `zipcode` 的係數？

本研究將 `zipcode` 當成數值型變數輸入 OLS。郵遞區號本質上是地理區域的識別碼，並不具有自然的連續尺度。

假設模型係數為負，也不能解釋成「郵遞區號每增加 1，房價就下降固定金額」。因為郵遞區號相差 1，不代表地理距離相同，也不代表房價應有固定方向的變化。

這是目前模型的重要限制。若將 `zipcode` 改為類別變數，模型可以比較不同郵遞區號區域相對於基準區域的價格差異，但也會增加模型欄位數量。因此，本研究的 `zipcode` 係數應視為一項簡化處理，而不是具有直接經濟意義的連續效果。

---

5. 五大回歸假設：哪些通過、哪些沒有通過？

線性回歸的評估不能只看 R^2，也需要檢查模型假設是否合理。依據本研究提供的診斷數值，可以初步整理如下。

假設或診斷項目	本次結果	判讀
線性關係	尚未提供完整診斷數值	無法確認完全成立
誤差獨立性	Durbin–Watson = 2.010	未見明顯的一階自相關訊號
同質變異性	$\lvert$殘差$\rvert$ 與配適值相關 = 0.496	顯示可能存在異質變異
殘差常態性	殘差偏態 = 3.540	明顯右偏，不符合對稱常態的特徵
無嚴重多重共線性	最大 VIF = 7.854	存在一定程度的共線性疑慮，需進一步判斷

（1）線性關係

多元線性回歸假設目標變數與輸入特徵之間的關係，能夠由線性組合合理描述。

目前沒有提供殘差與配適值圖、部分殘差圖或其他線性診斷結果，因此不能直接判定此假設通過。若殘差圖呈現彎曲、U 形或其他系統性規律，代表模型可能未充分描述變數之間的關係。

（2）誤差獨立性

Durbin–Watson 統計量為 2.010，接近 2，通常代表沒有明顯的一階殘差自相關。

因此，從這項指標來看，未觀察到強烈的一階自相關訊號。不過，Durbin–Watson 主要用於檢查特定形式的殘差自相關，不能單獨證明所有誤差都完全獨立。由於房屋交易具有地理位置與時間上的群聚性，仍可能存在未被此指標捕捉的空間或群聚相關。

（3）同質變異性

本研究中，絕對殘差與配適值的相關係數為 0.496，顯示預測房價增加時，殘差的絕對大小可能也傾向增加。

這與同質變異性的理想情況不一致，可能代表模型存在異質變異，也就是不同價格範圍的預測誤差分散程度不同。

這項結果是異質變異的警訊，但相關係數本身不是正式的異質變異檢定，最好搭配殘差圖或 Breusch–Pagan 檢定確認。

（4）殘差常態性

殘差偏態為 3.540，代表殘差分布明顯右偏，可能存在少數正向幅度很大的殘差，也就是模型對某些房屋的實際價格低估很多。

這與常態分布的對稱特徵不符，因此不能認為殘差常態性已經成立。

不過，殘差不常態並不代表 OLS 的係數估計一定無效。它主要影響傳統小樣本推論中信賴區間與假設檢定的可靠性，並可能與極端房價及模型未捕捉的非線性關係有關。

（5）多重共線性

最大 VIF 為 7.854，表示至少一個特徵可以由其他特徵相當程度地解釋。

VIF 的判斷門檻並非絕對：有些分析採用 5 作為需要注意的參考值，有些則以 10 作為較嚴重的警戒值。因此，7.854 比較適合解讀為存在值得注意的共線性，而不是直接宣告模型失敗。

在本資料中，居住面積、地上樓層面積、地下室面積與鄰近房屋面積之間可能存在資訊重疊。這種共線性會使個別係數較不穩定、標準誤可能增加，但不一定會明顯降低整體預測能力，也能解釋為什麼 RidgeCV 與 OLS 的測試 R^2 都是 0.6950。

殘差右偏與異質變異對預測區間的影響

本研究的高價房屋容易被低估，且少數低價房屋的預測值可能略低於 0。這反映線性模型在極端價格區域的限制。

傳統 OLS 的預測區間通常假設誤差結構合理，若殘差明顯右偏、變異程度又隨預測價格改變，區間可能無法在所有價格範圍維持理想的 95% 覆蓋率。

因此，報告中的 95% 預測區間應理解為**在模型假設下計算的估計範圍，而不是保證 95% 的實際房價一定會落在區間內**。尤其是高價房屋，可能需要更審慎地解讀預測結果。

---

6. 信賴區間與預測區間的差異：為什麼要畫在同一張圖？

信賴區間與預測區間雖然都可以呈現為預測線周圍的陰影帶，但兩者代表的統計意義不同。

（1）95% 平均數信賴區間

信賴區間用來描述在特定特徵條件下，模型估計的**平均房價**有多大的不確定性。

例如，對於具有相同指定特徵條件的一群房屋，模型會估計其平均價格。由於模型係數是從有限的訓練資料估計而來，因此這個平均價格並非完全確定，而是有一個估計範圍。

95% 信賴區間的涵義是：如果在相同條件下反覆抽樣、重新估計模型並建立區間，使用正確方法所建構的區間約有 95% 能涵蓋真正的平均反應。它不是指某一間新房屋有 95% 機率落在該區間內。

（2）95% 預測區間

預測區間用來描述**單一新房屋的實際價格**可能落在哪個範圍。

除了模型估計平均房價的不確定性之外，個別房屋本身也存在無法由現有特徵完全解釋的差異，例如裝潢品質、屋況細節、交易條件與其他未觀測因素。

因此，預測區間同時考慮平均估計的不確定性與個別觀測值的誤差，通常會比平均數信賴區間寬。

比較項目	平均數信賴區間	預測區間
估計對象	條件下的平均房價	單一新房屋的實際價格
是否考慮個別房屋的隨機誤差	不直接包含個別誤差	包含
區間寬度	通常較窄	通常較寬
實際用途	了解平均趨勢估計的不確定性	了解個別房價預測可能的誤差範圍

（3）為什麼把兩種區間畫在同一張圖？

將兩種區間畫在同一張預測圖上，可以清楚呈現兩種不同層次的不確定性。

- 中間的預測線呈現模型估計的平均價格趨勢。
- 較窄的 95% 信賴區間顯示平均趨勢估計的精確程度。
- 較寬的 95% 預測區間則呈現單一新房屋價格可能的波動範圍。

這種呈現方式能讓讀者理解，即使模型對平均房價的估計相對精確，個別房屋的實際交易價格仍可能有很大的差異。

對本研究而言，高價房屋被低估且殘差具有右偏與異質變異的現象，更凸顯了預測區間的重要性。它可以提醒使用者，房價預測不是單一確定答案，而是必須搭配誤差範圍一起解讀。

---

7. 為什麼其他研究使用 log(price)、類別型 zipcode 或樹模型時，R^2 常常更高？本研究為什麼仍採用 OLS？

King County 房價資料集是常見的回歸練習資料，因此網路上可以看到不同的前處理方式與模型。常見做法包括對房價取對數、將郵遞區號轉成類別變數，以及使用 Random Forest 或 Gradient Boosting 等非線性模型。

這些方法可能提高預測表現，但必須注意：**不同目標尺度、不同資料切分或不同前處理方式下得到的 R^2，不一定能直接公平比較。**

（1）使用 `log(price)`：降低極端高價房屋的影響

本資料的房價從 75,000 到 7,700,000，分布範圍相當大，而且殘差呈現明顯右偏。這代表少數高價房屋可能對平方誤差造成很大的影響。

將房價取自然對數後，模型改為預測：

$$\log(\text{price})$$

取對數可以壓縮高價與低價之間的尺度差距，讓模型更容易描述相對比例上的變化。例如，價格從 200,000 增加到 300,000，與從 2,000,000 增加到 2,100,000，雖然絕對差額都是 100,000，但其相對增幅並不相同。對數尺度能更自然地描述某些比例型關係。

此外，取對數有機會減少殘差右偏及異質變異的程度，因此可能改善模型假設與預測表現。

但取對數後的模型預測的是對數房價，不是原始房價。若要轉換回金額尺度，不能只把對數預測值當成原始價格；簡單使用指數函數還可能產生回轉偏差，需要適當的校正方法。

同時，對數模型的 R^2 是在對數房價尺度上計算，不能直接與原始房價模型的 R^2 當成完全相同的衡量標準。

（2）將 `zipcode` 當成類別變數：更能反映地區差異

郵遞區號是地區識別碼，不是真正的連續數值。若直接將它作為數值變數，OLS 會假設郵遞區號與房價之間存在單一線性關係，這個假設可能不符合真實的地理價格結構。

若將 `zipcode` 轉成類別變數，模型便能為不同地區估計相對於基準區域的價格差異，而不必假設郵遞區號數字增加時，房價會依固定方向改變。

這種做法可能提升模型表現，因為房價受到區域需求、生活機能、學區、交通與社區環境等因素影響，而這些資訊可能無法單靠 `lat` 與 `long` 的線性係數完整描述。

不過，將郵遞區號轉為類別變數會增加模型參數，也可能讓模型更容易記住訓練資料中特定地區的價格模式。因此，仍需使用適當的測試集或交叉驗證，確認效能改善能否泛化到新資料。

（3）使用 Random Forest 或 Gradient Boosting：捕捉非線性與特徵交互作用

OLS 的主要限制是預測值由輸入特徵的線性組合構成。即使有多個特徵，模型仍不會自動學習所有複雜的非線性關係。

例如，房屋面積增加帶來的價格變化，可能因地段、建築品質或景觀不同而有所差異；水岸條件的價值，也可能依區域而不同。

Random Forest 透過多棵決策樹的集成預測，能夠捕捉較複雜的非線性關係。Gradient Boosting 則逐步建立新的模型來改善先前的預測誤差，通常也能有效描述特徵之間的非線性關係與交互作用。

因此，這類模型在房價這種受多項因素影響、關係可能相當複雜的資料上，常有機會取得比基礎 OLS 更好的預測表現。

但較高的 R^2 不代表模型一定更適合所有研究目的。樹模型通常不會像 OLS 一樣，直接提供容易解讀的單一線性迴歸係數；若要說明模型如何作出預測，通常還需要搭配特徵重要性、部分依賴圖或 SHAP 等解釋方法。

（4）為什麼本研究仍以可解釋的 OLS 作為主要結果？

本研究的目標不只是追求最高的 R^2，也包括理解特徵選擇、分析係數方向、檢查回歸假設，以及呈現信賴區間和預測區間。

因此，OLS 有幾項優點：

1. **係數容易解釋：** 可以分析在其他特徵固定時，各特徵與預測房價的線性關聯。
2. **符合課程主題：** 直接對應多元線性回歸的模型建立、特徵選擇及模型評估要求。
3. **方便進行統計診斷：** 可以檢查殘差分布、異質變異、共線性及模型假設。
4. **適合比較特徵選擇：** 可以直接比較 18 個特徵與 14 個特徵模型，觀察精簡特徵是否仍保有相近的預測能力。
5. **容易建立統計區間：** 在適當假設下，可以計算平均反應的信賴區間與個別觀測值的預測區間。

本研究結果顯示，Forward SFS 選出的 14 特徵模型，測試 R^2 從 0.6950 微幅提升至 0.6954，RMSE 也略為降低；RidgeCV 的測試 R^2 則與完整 OLS 相同，都是 0.6950。

這表示在目前的資料切分與實驗設定下，精簡特徵可以維持相近的預測表現，而加入 Ridge 正則化並未在這次測試中帶來明顯的 R^2 提升。這不代表其他模型一定沒有優勢，而是說明在本次作業的研究目標下，OLS 已能提供可用的基準結果，並兼顧預測能力與可解釋性。

總結而言，OLS 是本研究的主要分析模型，而不是宣稱它是所有房價預測方法中準確率最高的模型。 若未來研究目標改為盡可能提高預測效能，可以再將 `log(price)`、類別型 `zipcode`、Random Forest 與 Gradient Boosting 納入比較，並在相同的資料切分、評估尺度與驗證流程下進行公平評估。

2026/10/14 下午8:53:33 · gpt-6