DIC2 HW2 多元線性迴歸報告

資料來源

Kaggle「House Sales in King County, USA」。

https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

本地檔 data/kc_house_data.csv，共 21613 筆、21 欄。目標是 price。去掉 id 與 date 後有 18 個原始預測變數，落在作業要求的10–20，也落在補充條件的14–39。

為什麼不是Predict the Flood

補充建議的第一名是 Kaggle Playground S4E5，原始 20 個數值特徵，本來最合適。不需登入就能下載的那份公開CSV，FloodProbability 恰好等於 0.005 乘上 20 個特徵的總和，線性回歸測試R^2 為 1。那種資料做特徵選擇沒有意義，所以沒有拿來當成果。

【CRISP-DM】

1. Business Understanding：買家與估價需要一個可解釋的成交價模型，而不是只追求黑盒分數。

2. Data Understanding：21613 筆、無缺值。價格最小 75000、中位數 450000、最大 7700000。sqft_living、sqft_above、sqft_basement 尺度大且彼此相關。

3. Data Preparation：刪除 id、date。80/20 分割，random_state=0，訓練 17290、測試 4323。特徵選擇只用訓練集。

4. Modeling：sklearn LinearRegression。五條路徑是 Lasso 係數排序、Forward SFS、RFE、SelectKBest、Permutation Importance。另報RidgeCV 當收縮對照，不混進 OLS 排名。

5. Evaluation：全部特徵的測試MSE 是 36326416754.06，R^2 是 0.6950。最好的OLS 子集是 Forward SFS，k=14，測試MSE 36274683097.02，RMSE 190459.14，MAE 122124.90，R^2 0.6954。RidgeCV 測試MSE 36323730877.54，R^2 0.6950。

6. Deployment：網頁用這組係數做即時估價，並畫出 95% 信賴區間與 95% 預測區間。

採用的特徵

sqft_living, lat, view, grade, yr_built, waterfront, bedrooms, bathrooms, zipcode, long, condition, sqft_above, sqft_living15, yr_renovated

回歸假設

殘差偏態3.540。絕對殘差與配適值的相關0.496。Durbin-Watson 2.010。最大 VIF 7.854。

房價右偏，殘差不是常態，而且大房子的誤差比較大，變異數不齊。這是這類資料的常見現象，不是程式算錯。對數價格是公開分析裡常見的下一步；本報告主模型仍用原始美元，讓區間可以直接讀成價格。VIF 若偏高，通常來自家中面積欄位彼此重疊，特徵選擇就是在處理這件事。

【主流 解法比 較】

King County 的公 開筆記本多半把 price 取對 數，再把 zipcode 做成 目標編 碼或分組，然 後用 Random Forest 或 Gradient Boosting。那些 模型 的測 試 R^2 常常高於 單純 線性 回歸，但係 數不好直接 解釋，也沒有線性 模型這 種預 測區 間。這份作業 保留線性 回歸，用五 種特 徵選擇處 理共 線性，並 把區 間畫出來 。Ridge 用來 對 照收 縮；它 的測 試誤 差和全 部特 徵的 OLS 接近， 因為這批 資料 的樣本 數遠大 於特 徵數，收 縮 的幫助 有 限。

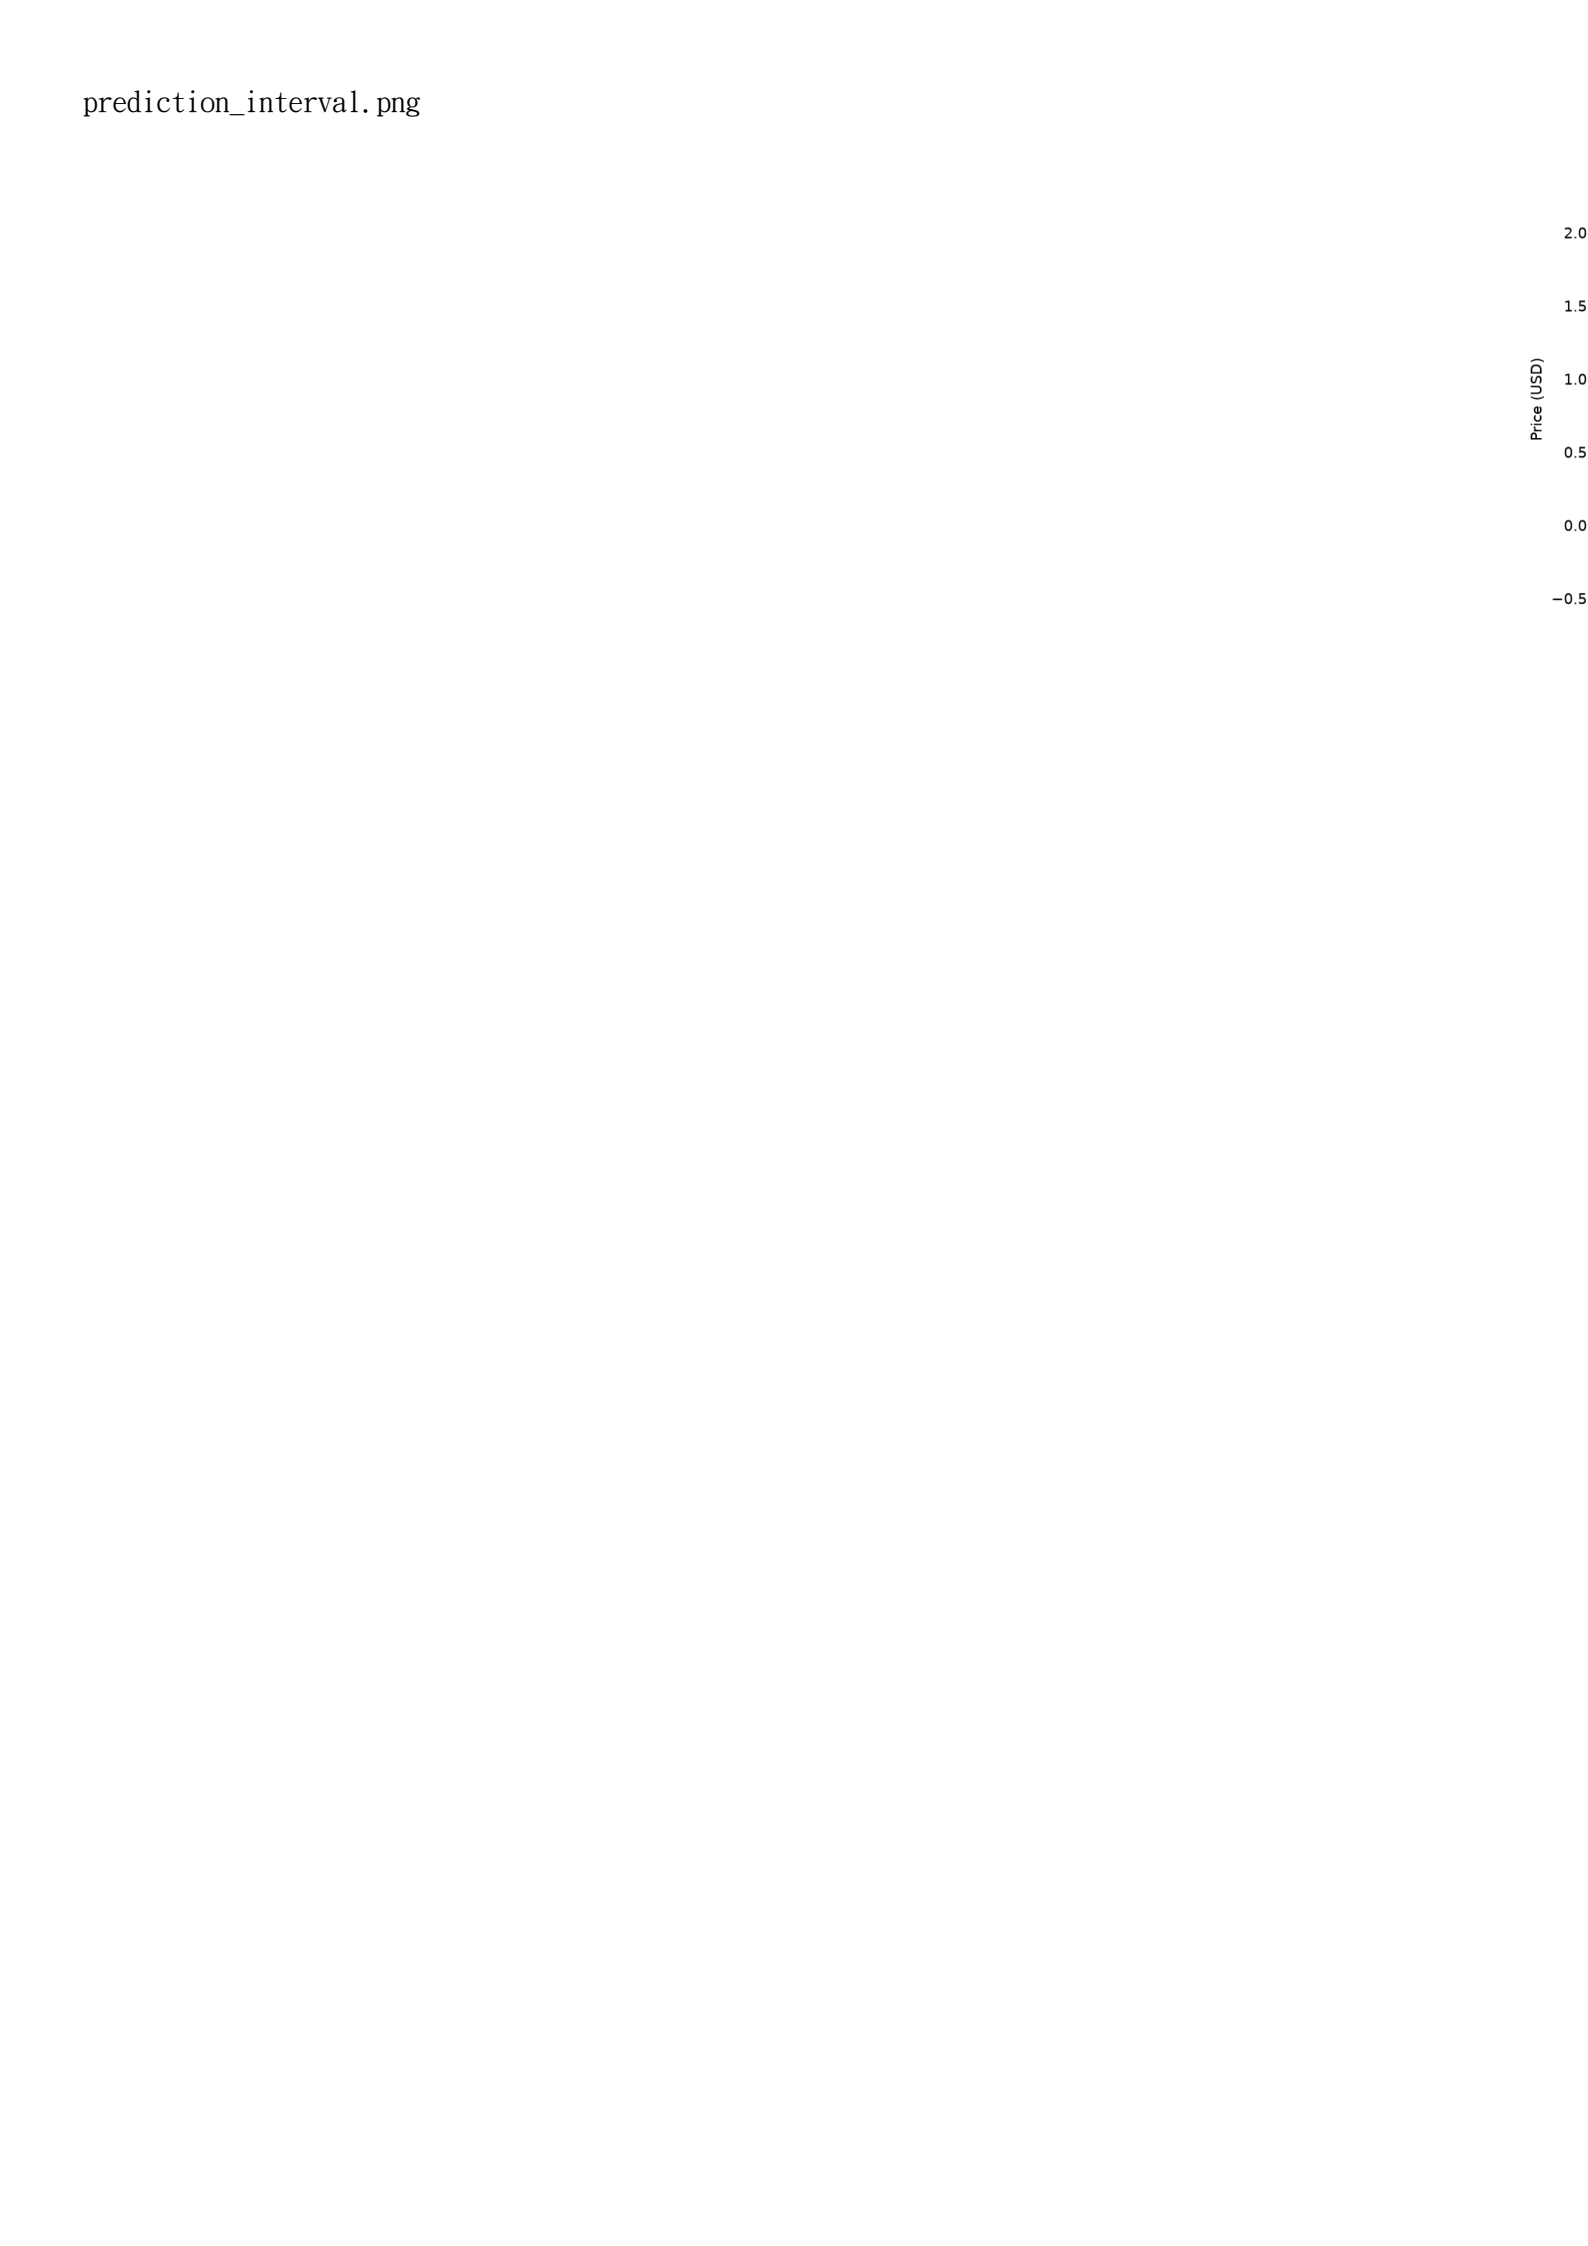
【NotebookLM 摘 要】

以 下是依公 開的 King County 房價 回歸做法 整理 的研究摘 要，超過 100 字。正式 繳交 前，請把 同主 題資料 貼進 NotebookLM，用它 自己的摘 要取 代這一 段，並 在報 告標 明「NotebookLM 摘 要」。King County 成交 價幾乎 都先 看居住 面積、等 級 grade、 臨水 waterfront 與經 緯度。多 數寫法 會先 取對 數價格， 因為 原始 價格 右偏、殘差 隨房價變大 。zipcode 不適 合直接 當連續 數字 ， 常見做法 是目標編 碼或只留緯經 度。線性 回歸能給出 每 個特 徵 的美元 係 數，R^2 多 半 落在 0.65 到 0.75； 樹模型與 梯度提升 通 常 更高，但 難以 做預 測區 間。面積欄位高度相 關，所以 Lasso、RFE 或乎 動刪掉 sqft_above 與 sqft_basement 其 中一 個，是公 開解法 裡反 覆出 現 的步 驟。本 作業 沿用這 個脈 絡，但主 模型維持 原始 價格 的 OLS，以 便區 間用美元 呈現。

【GPT 輔助 內容】

程式 架構、CRISP-DM 分 段、五 種特 徵選擇 的比 較 預 測區 間圖，以 及這份報 告草稿，是在 Cursor 裡 由 GPT 協助完成 。 評分 要求 的 pdfCrowd ChatGPT 對 話 PDF 無法 由這裡代為 登入 匯出 。 請自行 開啟 ChatGPT 對 話，用 pdfCrowd 匯出 PDF，放 進以學 號命名 的 zip，並 在報 告封 面標 明「GPT 輔助 內容」。主 程式 檔名 請改 成學 號hw2.py 再繳交 。

prediction_interval.png



residual_diagnostics.png

