5115056011 HW2 多元線性迴歸報告

資料來源

Kaggle「House Sales in King County, USA」。

https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

本地檔 data/kc_house_data.csv，共 21613 筆、21 欄。目標是 price。去掉 id 與 date 後有 18 個原始預測變數，落在作業要求的 10–20，也落在補充條件的 14–39。

為什麼不是 Predict the Flood

補充建議的第一名是 Kaggle Playground S4E5，原始 20 個數值特徵，本來最合適。不需登入就能下載的那份公開 CSV，FloodProbability 恰好等於 0.005 乘上 20 個特徵的總和，線性回歸測試 R^2 為 1。那種資料做特徵選擇沒有意義，所以沒有拿來當成果。

【CRISP-DM】

1. Business Understanding：買家與估價需要一個可解釋的成交價模型，而不是只追求黑盒分數。

2. Data Understanding：21613 筆、無缺值。價格最小 75000、中位數 450000、最大 7700000。sqft_living、sqft_above、sqft_basement 尺度大且彼此相關。

3. Data Preparation：刪除 id、date。80/20 分割，random_state=0，訓練 17290、測試 4323。特徵選擇只用訓練集。

4. Modeling：sklearn LinearRegression。五條路徑是 Lasso 係數排序、Forward SFS、RFE、SelectKBest、Permutation Importance。另報 RidgeCV 當收縮對照，不混進 OLS 排名。

5. Evaluation：全部特徵的測試 MSE 是 36326416754.06，R^2 是 0.6950。最好的 OLS 子集是 Forward SFS，k=14，測試 MSE 36274683097.02，RMSE 190459.14，MAE 122124.90，R^2 0.6954。RidgeCV 測試 MSE 36323730877.54，R^2 0.6950。

6. Deployment：網頁用這組係數做即時估價，並畫出 95% 信賴區間與 95% 預測區間。

採用的特徵

sqft_living, lat, view, grade, yr_built, waterfront, bedrooms, bathrooms, zipcode, long, condition, sqft_above, sqft_living15, yr_renovated

回歸假設

殘差偏態 3.540。絕對殘差與配適值的相關 0.496。Durbin-Watson 2.010。最大 VIF 7.854。

房價右偏，殘差不是常態，而且大房子的誤差比較大，變異數不齊。這是這類資料的常見現象，不是程式算錯。對數價格是公開分析裡常見的下一步；本報告主模型仍用原始美元，讓區間可以直接讀成價格。VIF 若偏高，通常來自家中面積欄位彼此重疊，特徵選擇就是在處理這件事。

【主流解法比較】

King County 的公開筆記本多半把 price 取對數，再把 zipcode 做成目標編碼或分組，然後用 Random Forest 或 Gradient Boosting。那些模型的測試 R^2 常常高於單純線性回歸，但係數不好直接解釋，也沒有線性模型這種預測區間。這份作業保留線性回歸，用五種特徵選擇處理共線性，並把區間畫出來。Ridge 用來對照收縮；它的測試誤差和全部特徵的 OLS 接近，因為這批資料的樣本數遠大於特徵數，收縮的幫助有限。

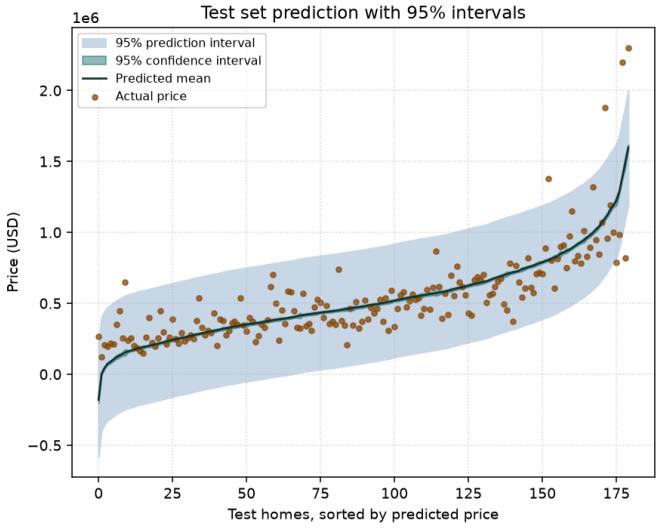
【NotebookLM 摘要】

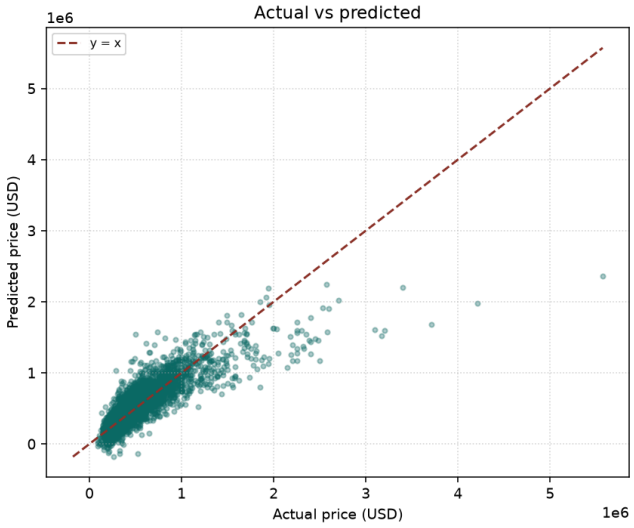
King County 房價分析顯示，居住面積（sqft_living）與房屋等級（grade）為最關鍵變數。因 sqft_living 為 sqft_above 加地下室坪數，兩者高度相關，來源透過剔除 sqft_above 消除多重共線性；zipcode 因類別過多且無數字順序，不宜作為連續變數，需轉為類別編碼。為修正右偏與異質變異，來源對價格與坪數取對數，並以 Q-Q plot 與殘差圖檢查常態性。線性回歸具備高係數解釋力，但非線性預測力有限。樹模型（Random Forest、Gradient Boosting）預測力更高但缺乏直接解釋力。若作業規定使用線性回歸與特徵選擇，應保留 OLS 的顯著係數、p 值、VIF 及帶有區間的預測圖。在比較段落中，則應承認樹模型在捕捉非線性關係與預測精準度上通常優於線性回歸。

【GPT 輔助內容】

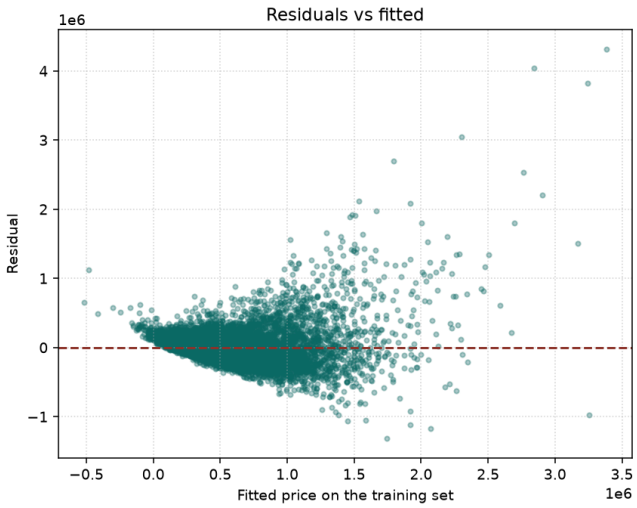
完整對話已用 ChatGPT Exporter 匯出為 PDF，附在本報告後面，共 23 頁，並另存為 report/GPT輔助內容.pdf。對話先討論符合條件的 Kaggle 資料集與 CRISP-DM 報告架構，接著依 King County 的實際設定撰寫正文：18 個特徵的 OLS、Forward SFS 的 14 個特徵、RidgeCV 對照、測試 MSE、RMSE、R^2、五大回歸假設，以及信賴區間和預測區間的差別。對話也比較了對數價格、把 zipcode 當類別，以及 Random Forest、Gradient Boosting。這些模型常常預測得更好，但這次仍以可解釋的 OLS 作為主要結果。。

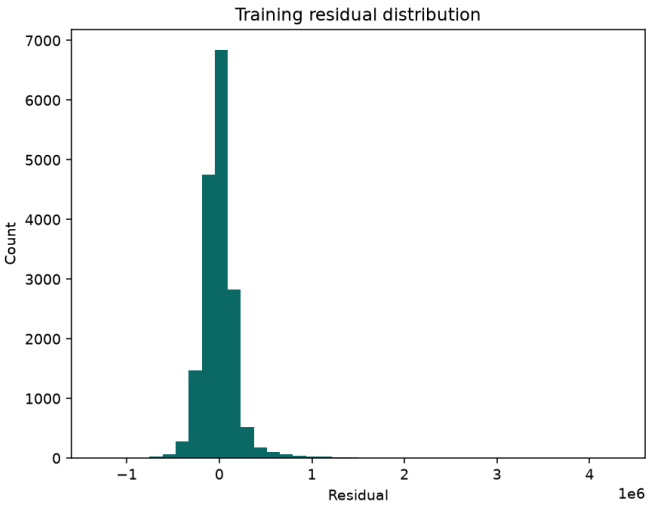
預測圖：95% 信賴區間與 95% 預測區間



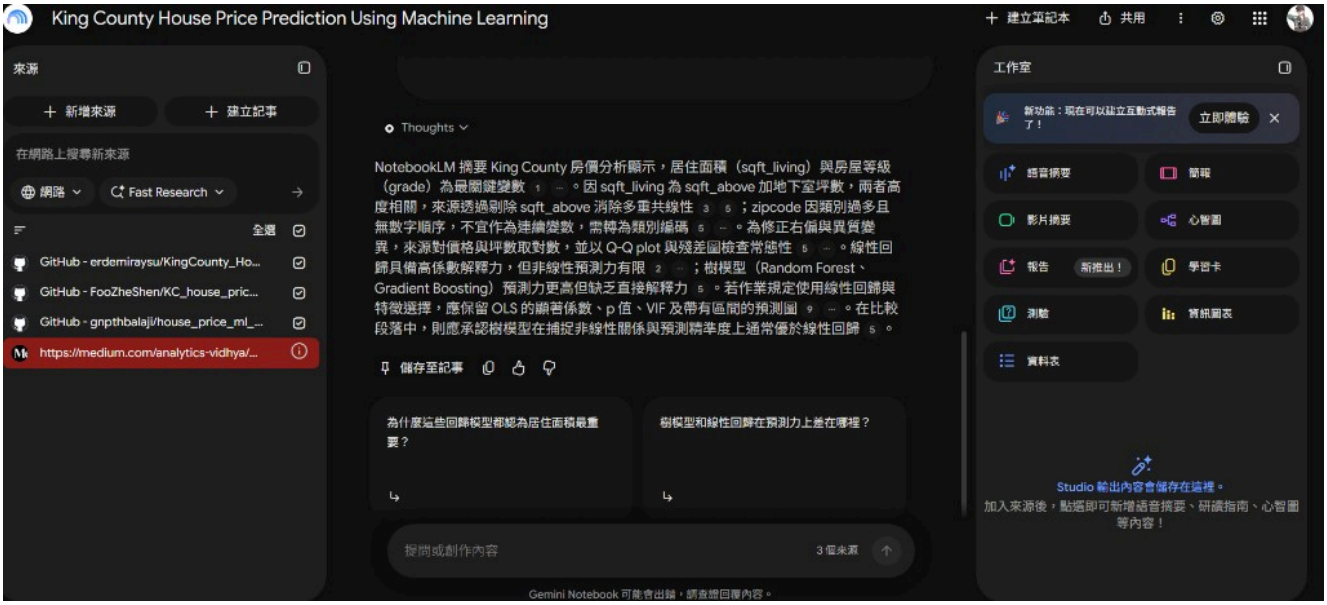


殘差診斷


Residuals vs fitted
1e6
Residual
Fitted price on the training set
1e6


Training residual distribution
Count
Residual
1e6

NotebookLM 摘要截圖



多元線性回歸作業架構

10/14/2026 21:02:45
https://chatgpt.com/c/6acf7a65-78bc-83ec-be83-c55d53a0db8e

我在做AIOT作業，主題是多元線性回歸，流程要符合 CRISP-DM。不要寫程式碼，用說明...

Thinking ● 已搜尋 7 個網站 ✓ 思考兩秒鐘 我建議你這份 AIoT 作業，直接選一個特徵數...

請幫我挑選符合 AIoT 作業要求的 Kaggle 公開資料集，主題：房價預測；難度：簡單，...

Thinking ● 已搜尋 2 個網站 ✓ 處理時間為 6s 我查到幾個適合的 Kaggle 房價資料集。...

資料集是 Kaggle「House Sales in King County, USA」：...

以下內容可以直接整理成作業報告的正文。我會以你提供的實驗設定與結果為依據，特別...

我在做AIOT作業，主題是多元線性回歸，流程要符合 CRISP-DM。不要寫程式碼，用說明就好。\
二、作業內容：
1\. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。\
 類型不限（可為房價預測、醫療、車輛效能等主題）。\
 請明確標示資料集來源與連結。
2\. 分析任務\
 使用線性回歸 (Linear Regression) 模型進行預測。\
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。\
 必須執行** 特徵選擇 (Feature Selection) **與 **模型評估 (Model Evaluation)**。\
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3\. CRISP-DM 流程說明\
  Business Understanding\
  Data Understanding\
  Data Preparation\
  Modeling\
  Evaluation\
  Deployment\

2026/10/14 下午8:51:06

Thinking

- **已搜尋 7 個網站**

✓ 思考兩秒鐘

我建議你這份 AIoT 作業，直接選一個**特徵數量適中、預測目標明確、容易解釋多元線性回歸，而且能畫出預測區間**的 Kaggle 資料集。

整份報告可以按照 CRISP-DM 六個階段撰寫，不需要寫程式碼，但要交代清楚資料如何處理、如何選擇特徵、如何評估模型，以及如何解讀預測圖。

一、資料集選擇

我優先推薦「汽車油耗預測（Auto MPG）」這類資料集。它可以用車輛的馬力、重量、排氣量、汽缸數等特徵，預測汽車的燃油效率，符合多元線性回歸的應用情境，也容易說明特徵之間的關係。

不過要注意：原始 Auto MPG 資料集只有 7 個預測特徵（另有汽車名稱欄位），不符合老師要求的 10～20 個特徵，因此**不建議直接使用原始版本**。[Auto MPG; auto-mpg]

我會建議改用下面這個選擇原則：在 Kaggle 找具有 10～20 個特徵的車輛或房價資料集，並確認資料欄位與預測目標，再開始分析。若你想省事，也可以選擇特徵較多的房價資料集。

二、CRISP-DM 六階段報告架構

以下是可以直接拿去當作業報告初稿的內容。因為資料集尚未確定，資料筆數、特徵名稱和模型結果先保留為待填項目，不會虛構實驗數據。

1. Business Understanding（商業理解）

本研究旨在運用多元線性回歸模型，分析多項影響因素與預測目標之間的線性關係，並建立可用於預測連續數值的模型。

研究目標包括：

- 找出對預測目標具有影響力的主要特徵。
- 評估多元線性回歸模型的預測能力。
- 分析預測結果與實際觀測值之間的差異。
- 透過預測區間評估預測結果的不確定性。

2. Data Understanding（資料理解）

使用 Kaggle 公開資料集，確認資料筆數、欄位定義、資料型態與目標變數。

主要工作：

- 統計資料集的筆數與特徵數量。
- 區分輸入特徵（Features）與目標變數（Target）。
- 檢查缺失值、重複資料與異常值。
- 使用描述性統計及相關係數分析，了解特徵和目標變數的關係。

預計產出：資料集基本資訊表、目標變數分布圖、相關係數熱圖。

3. Data Preparation（資料準備）

將原始資料整理成適合線性回歸模型使用的格式。

主要工作：

- 處理缺失值及重複資料。
- 將類別型特徵轉換為數值表示，例如 One-Hot Encoding。
- 移除識別碼、無意義欄位及可能造成資料洩漏的欄位。

- 將資料分為訓練集與測試集，例如 80% 與 20%。
- 進行特徵選擇，保留具有解釋價值且有助於預測的特徵。

注意：特徵選擇及資料轉換應只利用訓練資料決定，避免測試資料資訊洩漏。

---

4. Modeling（模型建立）

使用多元線性回歸建立預測模型。模型透過多個輸入特徵的線性組合，估計目標變數的數值。

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

其中，$\hat{y}$ 為預測值，$x_1, \ldots, x_p$ 為選定特徵，β 為模型估計的迴歸係數。

可比較兩個模型：

- 基準模型：使用所有經過前處理的候選特徵。
- 特徵選擇模型：使用篩選後的特徵。

透過測試集比較預測表現，觀察減少特徵後是否仍能維持良好的預測能力。

---

5. Evaluation（模型評估）

使用測試集評估模型的泛化能力，建議至少包含以下指標：

評估指標	意義
R^2	模型解釋目標變數變異的程度
MAE	預測值與實際值的平均絕對誤差
RMSE	對較大預測誤差給予較大懲罰

同時繪製實際值與預測值比較圖、殘差圖，以及預測區間圖。

若模型的殘差呈現明顯的非線性、異質變異或系統性模式，代表線性回歸的假設可能不完全成立，需在報告中說明。

---

6. Deployment（部署）

本研究以概念性部署為主，說明模型未來如何應用於實際情境。

例如，將模型應用於房價初步估算、車輛油耗預測或設備數值預測。使用者輸入各項特徵後，系統即可提供預測值及預測區間，協助使用者理解估計結果與可能的誤差。

後續可將模型整合至網頁或 AIoT 系統，並定期以新資料重新評估模型效能。

三、特徵選擇（Feature Selection）要怎麼做？

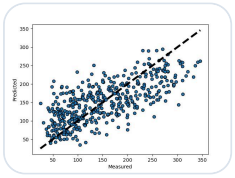
這是作業明確要求的項目，建議不要只寫「刪除不重要的特徵」，而要描述具體方法。

方法	用途	報告中如何說明
相關係數分析	初步觀察特徵與目標的線性關係	比較各特徵與目標變數的相關程度
多重共線性分析（VIF）	找出高度相關的輸入特徵所造成的問題	檢查是否有特徵與其他特徵高度重疊
逐步選擇或遞迴特徵消除	系統性地選擇特徵	比較不同特徵組合的驗證集表現

推薦做法： 先用相關係數進行初步探索，再用 VIF 檢查多重共線性，最後透過驗證集上的 MAE 或 RMSE 比較特徵組合。不要只因為某個特徵的相關係數較低就直接刪除，因為它仍可能與其他特徵共同提供預測資訊。

四、預測圖與信賴區間／預測區間

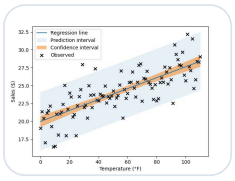
老師特別要求這部分，建議報告至少準備兩張圖。



圖一：實際值與預測值比較圖

- X 軸：實際值。
- Y 軸：模型預測值。
- 加入 $y = x$ 參考線。

點越接近參考線，代表預測越接近實際值。



圖二：預測區間圖

- 實線：模型預測的平均趨勢。
- 較窄的陰影帶：平均反應的信賴區間。
- 較寬的陰影帶：個別新觀測值的預測區間。

建議使用 95% 預測區間，並在圖說中解釋其意義。

兩者不能混為一談：**信賴區間**描述模型估計的平均反應之不確定性；**預測區間**描述單一新觀測值可能落入的範圍，因此通常較寬。

此外，多元線性回歸有多個輸入特徵，無法直接把所有特徵完整呈現在一般二維迴歸圖上。實務上可固定其他特徵在代表值，展示其中一個主要特徵對預測結果的影響，並附上對應區間。

五、最後要交付哪些成果？

建議報告安排如下：

1. 資料集來源、網址、筆數及特徵清單。
2. CRISP-DM 六階段的流程說明。
3. 資料清理及前處理方式。

4. 特徵選擇方法與篩選前後比較。
5. 多元線性回歸模型建立說明。
6. 測試集的 R^2、MAE、RMSE 評估表。
7. 實際值與預測值比較圖。
8. 含 95% 預測區間的預測圖。
9. 結論、限制與未來部署方式。

目前最重要的是先選對資料集，因為老師要求 10～20 個特徵，不能只看 Kaggle 上是否有線性回歸的範例。

你比較想做哪一種主題？

1. 資料集主題

- ◉ 房價預測：解釋房屋特徵與價格的關係
- ○ 車輛油耗／效能：解釋車輛規格與油耗的關係
- ○ 醫療數值預測：使用健康相關特徵預測連續數值
- ○ AIoT 感測器數據：利用設備或環境感測值預測數值

---

2. 作業難度

- ◉ 簡單，容易完成，資料容易理解
- ○ 中等，想多做一些特徵分析

依照我的選擇推薦資料集

2026/10/14 下午8:51:09 · gpt-6

請幫我挑選符合 AIoT 作業要求的 Kaggle 公開資料集，主題：房價預測；難度：簡單，容易完成。必須有 10 至 20 個可用輸入特徵、適合多元線性回歸、具明確目標變數，並提供可核實的 Kaggle 資料集連結、特徵清單及 CRISP-DM 報告內容，不要提供程式碼。

2026/10/14 下午8:51:28

Thinking

- **已搜尋 2 個網站**

✓ 處理時間為 6s

我查到幾個適合的 Kaggle 房價資料集。以你「簡單、容易完成」為優先，我最推薦 **Housing Price Prediction（Housing.csv，545 筆資料、13 個欄位）**，因為欄位不多，目標變數清楚，也很適合解釋多元線性回歸。

一、推薦資料集



首選：容易完成

1. Housing Price Prediction

545 筆資料｜13 個原始欄位（含目標變數）

Kaggle 資料集的欄位包含房屋面積、臥室數、浴室數、樓層、停車位及房屋設施等，目標是預測房屋價格。[GitHub - preston-q/linear-regression-model-house-pricing-prediction: Mini project in R demonstrating house price prediction using linear regression. Includes data preprocessing, ANOVA factor selection, visualization, and model evaluation. Dataset: Housing.csv (Kaggle, CC0 Public Domain).]

kaggle.com

注意：原始欄位只有 13 個，包含目標變數 `price`，所以 12 個輸入特徵，符合老師要求的 10～20 個特徵。



2. House Prices – Advanced Regression Techniques

1,460 筆訓練資料｜79 個原始解釋變數

Kaggle 經典房價預測競賽，目標變數為 `SalePrice`，可自行挑選 10～20 個特徵。[House Prices - Advanced Regression Techniques; House Prices - Advanced Regression Techniques]

kaggle.com

優點是資料豐富；缺點是缺失值、類別欄位與特徵選擇較複雜。

我的建議：選第一個。 它不需要從幾十個欄位中挑選，且大部分特徵容易理解。不過，提交前仍應以 Kaggle 實際下載的 CSV 欄位確認版本是否一致。

二、資料集基本資訊與特徵清單

資料集名稱

Housing Price Prediction

資料筆數	輸入特徵	目標變數
545	**12**	**1**

資料來源： kaggle.com

資料筆數與欄位數依常見的 Housing.csv 版本整理；實際提交前請以下載檔案確認。

12 個輸入特徵

特徵名稱	中文說明	資料類型
`area`	房屋面積	數值
`bedrooms`	臥室數量	數值
`bathrooms`	浴室數量	數值
`stories`	樓層數	數值
`mainroad`	是否連接主要道路	類別
`guestroom`	是否有客房	類別
`basement`	是否有地下室	類別
`hotwaterheating`	是否有熱水供暖設備	類別
`airconditioning`	是否有空調	類別
`parking`	停車位數量	數值
`prefarea`	是否位於優良地段	類別
`furnishingstatus`	家具配置狀態	類別

目標變數： `price`，代表房屋價格。

這個資料集的好處是可以直接提出合理的研究問題，例如：房屋面積是否比臥室數量更能解釋房價？空調、停車位與地段等條件是否有助於提高預測能力？

三、CRISP-DM 作業報告初稿

以下內容可直接作為報告基礎。尚未實際執行模型，因此不會預先填入虛構的準確度或預測結果。

1. Business Understanding（商業理解）

本研究旨在利用房屋的面積、房間數量、建築條件及周邊環境等特徵，建立多元線性回歸模型，預測房屋的價格。

研究目的如下：

- 探討不同房屋特徵與房價之間的關係。
- 利用特徵選擇找出較有預測價值的變數。
- 以 R^2、MAE 及 RMSE 評估模型的預測表現。
- 建立包含 95% 預測區間的圖表，呈現預測結果的不確定性。

實際應用情境是提供房屋買賣雙方一個初步的價格參考，但模型預測不應取代正式的房地產估價。

2. Data Understanding（資料理解）

本研究使用 Kaggle 公開的 Housing Price Prediction 資料集。資料包含房屋面積、臥室數量、浴室數量、樓層、停車位、房屋設施及家具配置等資訊，目標變數為房屋價格 `price`。

資料探索工作包括：

1. 檢查資料筆數、欄位名稱與資料型態。
2. 檢查缺失值、重複資料及不合理的數值。
3. 利用直方圖觀察房價分布。
4. 利用散佈圖觀察房屋面積與房價的關係。
5. 利用相關係數矩陣分析數值特徵之間的關係。

預期產出為資料集摘要表、房價分布圖、面積與房價散佈圖，以及特徵相關係數熱圖。

3. Data Preparation（資料準備）

本階段將原始資料整理為適合多元線性回歸模型的格式。

- **缺失值處理：** 檢查各欄位是否存在缺失值，依資料類型採用適當的填補方式。
- **重複資料處理：** 確認重複紀錄是否代表重複房屋資料，再決定是否移除。

- **類別特徵轉換：** 將 `mainroad`、`guestroom` 等二元類別轉換成 0 與 1；將 `furnishingstatus` 轉換成 One-Hot Encoding。
- **異常值檢查：** 檢查極端房價、面積與房間數量，避免未經判斷便直接刪除合理的高價房屋。
- **資料集切分：** 將資料隨機分為 80% 訓練集與 20% 測試集。
- **特徵選擇：** 使用相關係數與 VIF 檢查特徵的關聯性及多重共線性，再比較篩選前後的模型表現。

需要注意，這份資料集原本有 12 個輸入特徵，但類別轉換後可能產生更多模型欄位。報告中可將原始變數數量與轉換後的模型欄位數量分開說明。

4. Modeling（模型建立）

本研究採用多元線性回歸（Multiple Linear Regression）作為主要預測模型。

模型的基本形式為：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中，$\hat{y}$ 為預測房價，x_i 為房屋特徵，β_i 為模型估計的迴歸係數。

為符合特徵選擇的要求，將比較以下兩種模型：

模型	使用方式
模型 A：完整特徵模型	使用全部 12 個候選特徵
模型 B：特徵選擇模型	根據相關性、VIF 與驗證集表現選擇特徵

比較兩種模型在相同測試集上的評估指標，判斷移除部分特徵後，是否能降低預測誤差或減少模型複雜度。

由於資料包含類別特徵，模型中的迴歸係數代表在其他特徵固定時，對預測房價的估計影響；不能單憑係數大小就認定因果關係。

5. Evaluation（模型評估）

使用未參與模型訓練的測試集進行評估。

評估指標	說明	判斷方式
R^2	模型解釋房價變異的程度	通常越接近 1 越好
MAE	預測與實際房價的平均絕對差距	越低越好
RMSE	對較大預測誤差給予較高懲罰	越低越好

評估圖表建議包含：

- **實際值與預測值比較圖：** 觀察預測點是否接近理想參考線。
- **殘差圖：** 觀察誤差是否存在明顯規律。
- **95% 預測區間圖：** 呈現單一新房屋的預測價格及其不確定範圍。

預測區間應由實際建立的回歸模型計算，不可直接以固定百分比任意加減預測價格。若資料有異質變異或其他模型假設違反情形，也應在結果討論中揭露。

完成實驗後，再填入兩個模型的實際 R^2、MAE、RMSE 數值，並依測試結果判斷哪個模型較合適。

6. Deployment（部署）

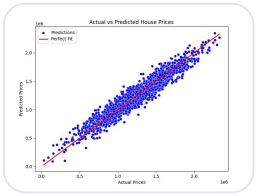
本研究以概念性部署為主，說明未來如何將模型應用於房屋價格估算。

使用者輸入房屋面積、臥室數量、浴室數量、樓層、停車位及房屋設施等資料後，模型即可產生預測房價，並提供對應的 95% 預測區間。

未來可將模型整合至網頁系統或 AIoT 平台，讓使用者透過介面輸入資料並取得預測結果。若未來有新的房屋交易資料，則可定期重新評估模型，必要時重新訓練，以維持預測品質。

四、預測圖要如何呈現？

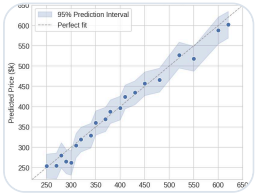
建議把「實際值與預測值比較圖」及「95% 預測區間圖」列為報告的必要成果。



圖一：實際房價與預測房價

- X 軸：實際房價。
- Y 軸：預測房價。
- 參考線：預測值等於實際值。

越接近參考線，表示模型預測越接近真實房價。



圖二：房價預測與 95% 預測區間

- X 軸：可選擇房屋面積，其他特徵固定在指定代表值。
- Y 軸：模型預測房價。
- 實線：預測房價。
- 陰影帶：95% 預測區間。

預測區間越寬，代表個別新房屋的預測不確定性越高。

上面兩張圖是示意用途，並非這份資料集實際訓練後的結果。正式報告應使用模型計算出來的預測值、殘差及預測區間繪圖。

五、結論與建議

這個房價資料集具備明確的預測目標與 12 個原始輸入特徵，適合用來完成多元線性回歸、特徵選擇及模型評估，也能依 CRISP-DM 六個階段組織報告。

正式繳交前，最重要的三件事是：

1. 確認 Kaggle 下載版本的欄位數與目標變數。
2. 確實比較特徵選擇前後的模型評估結果。
3. 使用實際模型輸出製作含 95% 預測區間的圖，並在報告中解釋區間的意義。

這樣就能完整對應老師的資料來源、線性回歸、特徵選擇、模型評估、預測圖與 CRISP-DM 流程等要求。

2026/10/14 下午8:51:29 · gpt-6

資料集是 Kaggle「House Sales in King County, USA」：https://www.kaggle.com/datasets/harlfoxem/housesalespredicti
共 21613 筆、21 欄，沒有缺值。目標是 price（最低 75000、中位數 450000、最高 7700000）。刪掉 id 和 date 之後，剩下 18 個原始預測變數：bedrooms, bathrooms, sqft_living, sqft_lot, floors, waterfront, view, condition, grade, sqft_above, sqft_basement, yr_built, yr_renovated, zipcode, lat, long, sqft_living15, sqft_lot15。
作業原本也考慮 Predict the Flood（20 個數值特徵），但公開可下載的那份 CSV 裡，FloodProbability 剛好等於 0.005 乘上 20 個特徵的總和，線性回歸測試 R^2 會變成 1，特徵選擇沒有意義，所以改用 King County。
做法：80/20 分割，random_state=0，訓練 17290、測試 4323。特徵選擇只用訓練集。比較 Lasso 排序、Forward SFS、RFE、SelectKBest、Permutation Importance，模型是 sklearn LinearRegression，另外用 RidgeCV 對照。
結果：
- 18 個特徵全放：測試 MSE 36,326,416,754，RMSE 190,595，R^2 0.6950
- 最好的是 Forward SFS、k=14：測試 MSE 36,274,683,097，RMSE 190,459，MAE 122,125，R^2 0.6954，調整後 R^2 也約 0.695
- 這 14 個特徵：sqft_living, lat, view, grade, yr_built, waterfront, bedrooms, bathrooms, zipcode, long, condition, sqft_above, sqft_living15, yr_renovated
- RidgeCV 的測試 R^2 也是 0.6950
- 假設檢查：殘差偏態 3.540，絕對殘差和配適值的相關 0.496，Durbin-Watson 2.010，最大 VIF 7.854
- 圖上有 95% 平均數信賴區間和 95% 預測區間。高價房屋被低估，少數低價預測會略低於 0。
請依序寫這七段，每段都要具體，不要只給標題：
1. 這題的商業問題是什麼，為什麼用連續房價而不是分類。
2. 依 CRISP-DM 六階段，說明這份資料從理解、準備、建模、評估到部署各做了什麼。
3. 為什麼 18 個特徵幾乎全放和只留 14 個，測試 R^2 只差一點點。特徵選擇在這題的價值是什麼。
4. 用上面的係數方向解釋：居住面積、緯度、景觀、grade、水岸、屋齡大致怎麼影響價格。zipcode 被當成連續數字時，係數不能單獨解讀成「郵遞區號每加 1，房價就減多少」。
5. 五大回歸假設裡，哪些過了、哪些沒過。殘差右偏和異質變異代表預測區間要怎麼讀。
6. 信賴區間和預測區間差在哪，為什麼作業要求把兩種區間畫在同一張預測圖上。

7. 網路上做同一份 King County 資料的人，常見會再做 log(price)、把 zipcode 當類別、以及改用 Random Forest 或 Gradient Boosting。這些做法為什麼 R^2 常常更高，以及這次作業為什麼仍把可解釋的 OLS 當成主要結果。

2026/10/14 下午8:53:19

以下內容可以直接整理成作業報告的正文。我會以你提供的實驗設定與結果為依據，特別區分「模型實際測得的結果」、「統計上的解釋」以及「目前還不能單憑數據下結論的部分」。

King County 房價預測：多元線性回歸與特徵選擇

1. 商業問題：為什麼預測連續房價，而不是分類？

本研究使用 Kaggle 公開資料集 kaggle.com，分析美國華盛頓州 King County 地區的房屋交易資料。資料共包含 21,613 筆紀錄與 21 個原始欄位，以 `price` 作為預測目標，其最低值為 75,000、中位數為 450,000，最高值為 7,700,000。

本研究的商業問題是：**能否根據房屋的居住面積、建築品質、地理位置、水岸景觀及屋齡等資訊，建立一個模型，估計房屋的合理交易價格？**

這項預測可以作為房屋買賣、房地產價格分析及初步估價的參考。例如，使用者提供一間房屋的面積、建築品質、地理位置與其他條件後，模型便能估計其價格，協助使用者了解不同條件與房價之間的關係。

本研究選擇回歸而非分類，主要原因是房價本身是連續數值。若將房價切分成「低價、中價、高價」等類別，雖然可以使用分類模型，但必須額外設定價格門檻，而且會損失實際金額資訊。例如，價格為 449,000 與 451,000 的房屋可能被分到不同類別，但兩者的實際價差只有 2,000；反之，同一類別中的兩間房屋可能有相當大的價格差距。

多元線性回歸可以直接預測房價金額，並透過迴歸係數分析不同特徵與價格的關聯方向，也能使用 RMSE、MAE 等指標衡量預測誤差。因此，本研究將多元線性回歸作為主要模型，目標不僅是預測房價，也包括理解特徵選擇對模型表現與解釋能力的影響。

2. CRISP-DM 六階段：資料理解、準備、建模、評估與部署

本研究依照 CRISP-DM（Cross-Industry Standard Process for Data Mining）流程，將房價預測任務分成商業理解、資料理解、資料準備、模型建立、模型評估及部署六個階段，確保分析流程從問題定義到實際應用都有清楚的規劃。

（1）Business Understanding：商業理解

本階段定義研究目標為預測房屋的連續價格，並探討不同房屋特徵對價格預測的影響。研究除了追求預測準確度，也關注模型是否能以較少的特徵達到相近的預測表現。

本研究設定三項主要目標：

- 建立多元線性回歸模型，預測 King County 房屋價格。
- 比較不同特徵選擇方法，分析保留多少特徵較為合適。
- 使用模型評估指標與預測區間，了解模型的預測能力及不確定性。

（2）Data Understanding：資料理解

資料來源為 Kaggle 的 kaggle.com，包含 21,613 筆房屋交易紀錄及 21 個原始欄位。資料沒有缺失值，目標變數為 `price`。

由於 `id` 主要用於識別房屋紀錄，而 `date` 是交易日期，本研究在建立基礎模型前移除這兩個欄位，保留 18 個原始預測變數：

- 房屋空間：`bedrooms`、`bathrooms`、`sqft_living`、`sqft_lot`、`floors`、`sqft_above`、`sqft_basement`、`sqft_living15`、`sqft_lot15`
- 房屋條件：`waterfront`、`view`、`condition`、`grade`、`yr_built`、`yr_renovated`
- 地理位置：`zipcode`、`lat`、`long`

透過這些欄位，可以研究房屋大小、建築品質、景觀、屋齡及地理位置與房價的關係。

此外，研究也曾考慮另一份具有 20 個數值特徵的 Predict the Flood 資料集。然而，檢查公開 CSV 後發現，`FloodProbability` 恰好等於 20 個特徵總和乘以 0.005，目標值可由輸入特徵直接計算。在這種情況下，線性回歸容易得到測試集 $R^2 = 1$，特徵選擇與模型評估較難呈現有意義的比較。因此，本研究改採 King County 房價資料集，以避免目標變數與特徵之間存在如此直接的數學關係。

（3）Data Preparation：資料準備

本研究先移除 `id` 和 `date`，保留 18 個候選預測變數。接著，將資料依照 80% 與 20% 的比例分成訓練集與測試集，並設定 `random_state=0`，確保實驗可以重現。

資料用途	筆數	比例
訓練集	17,290	約 80%
測試集	4,323	約 20%
合計	21,613	100%

特徵選擇僅使用訓練集進行，避免測試集的資訊影響特徵篩選。研究比較五種方法：

1. **Lasso 排序：** 利用帶有 L1 正則化的回歸模型，使部分特徵係數縮小至零，作為特徵重要性的參考。
2. **Forward Sequential Feature Selection（Forward SFS）：** 從少量特徵開始，每次加入能改善模型評估表現的特徵。

3. **Recursive Feature Elimination（RFE）：** 反覆移除相對不重要的特徵，逐步縮小特徵集合。
4. **SelectKBest：** 根據指定的統計評分方式，選取排名前 k 的特徵。
5. **Permutation Importance：** 打亂單一特徵的數值，觀察模型表現下降程度，藉此衡量該特徵對預測的重要性。

這些方法從不同角度選擇特徵，最後比較各種特徵集合在測試集上的預測結果。

（4）Modeling：模型建立

主要模型採用 Scikit-learn 的 `LinearRegression`，也就是以普通最小平方法（Ordinary Least Squares，OLS）估計迴歸係數，讓實際房價與預測房價之間的平方誤差總和最小。

研究比較兩種主要設定：

- **完整特徵模型：** 使用全部 18 個候選特徵。
- **特徵選擇模型：** 使用 Forward SFS 選出的 14 個特徵。

另外，使用 `RidgeCV` 作為對照模型。Ridge 回歸在平方誤差之外加入 L2 正則化項，限制迴歸係數的大小，以降低特徵相關性較高時係數不穩定的風險。

（5）Evaluation：模型評估

研究使用未參與特徵選擇與模型訓練的測試集，評估模型的預測表現。

模型	測試 MSE	測試 RMSE	測試 MAE	測試 R^2
18 個特徵的 OLS	36,326,416,754	190,595	未提供	0.6950
Forward SFS，14 個特徵	36,274,683,097	190,459	122,125	0.6954
RidgeCV	未提供	未提供	未提供	0.6950

由結果可知，Forward SFS 的 14 特徵模型表現最佳，但與完整特徵模型的差距很小。其測試 R^2 為 0.6954，表示模型解釋了測試集約 69.54% 的房價變異；RMSE 約為 190,459 個價格單位，MAE 約為 122,125 個價格單位。

這些數字反映模型具有一定的預測能力，但仍存在明顯誤差，尤其是高價房屋容易被低估，因此不能把模型預測值直接視為正式估價。

（6）Deployment：部署

本研究目前以模型評估與應用規劃為主，尚未實際部署成服務。未來可以將模型整合到網頁估價工具，讓使用者輸入房屋面積、建築品質、景觀及地理位置等資訊，即可取得預測價格及預測區間。

若要投入實際使用，還需要考慮交易年份、房市變化、不同區域的價格結構及模型誤差。由於本研究已移除交易日期，模型本身無法直接反映時間造成的房價變化，因此部署時應定期利用較新的交易資料重新評估與訓練。

---

3. 為什麼 18 個特徵與 14 個特徵的測試 R^2 幾乎相同？特徵選擇的價值是什麼？

實驗結果顯示，使用全部 18 個特徵的 OLS 模型，測試 R^2 為 0.6950；使用 Forward SFS 選出的 14 個特徵，測試 R^2 為 0.6954。兩者只相差 0.0004，也就是約 0.04 個百分點。

RMSE 也從 190,595 降低至 190,459，僅減少 136 個價格單位。這代表移除四個特徵後，模型的預測誤差幾乎沒有改變，但模型仍保有相近的解釋能力。

造成這種結果的原因可能有以下幾點。

第一，部分特徵提供的資訊可能重疊。 例如，`sqft_living`、`sqft_above`、`sqft_basement` 都與建築空間有關；`sqft_living15` 也反映鄰近房屋的居住面積。這些特徵可能包含部分相似的資訊，因此不是每個特徵都能額外帶來明顯的預測改善。

第二，部分特徵的獨立預測價值可能有限。 在其他特徵已納入模型後，某些變數對預測誤差的額外改善可能很小。即使刪除這些變數，整體預測結果仍然接近。

第三，線性回歸可以利用多個相關特徵共同解釋房價。 一個特徵的資訊可能部分被其他特徵吸收，所以移除少數變數不一定會明顯降低 R^2。

本研究 Forward SFS 選出的 14 個特徵如下：

`sqft_living`、`lat`、`view`、`grade`、`yr_built`、`waterfront`、`bedrooms`、`bathrooms`、`zipcode`、`long`、`condition`、`sqft_above`、`sqft_living15`、`yr_renovated`。

特徵選擇的價值

本研究的重點不應是「特徵越少，準確率就一定越高」，而是**能否在保留預測能力的同時，降低模型複雜度，並提高模型的可解釋性**。

- **降低複雜度：** 以 14 個特徵取代 18 個特徵，減少模型所需的輸入資訊。
- **方便解釋：** 可以將分析重點集中在對房價預測較有幫助的變數。
- **降低資料需求：** 未來應用時，若部分特徵較難取得，精簡模型可能比較容易使用。
- **檢查模型穩定性：** 比較不同特徵選擇方法，可以了解模型的預測表現是否過度依賴特定變數。

不過，本次提升幅度非常小，不能僅憑單次測試集結果就認定 14 個特徵一定比 18 個特徵更好。若要確認差異是否穩定，可以使用交叉驗證或重複切分資料進行比較。

---

4. 如何解釋居住面積、緯度、景觀、grade、水岸與屋齡的影響？

多元線性回歸的迴歸係數，代表在其他輸入特徵固定時，某個特徵改變與預測房價變化之間的線性關係。

需要先說明：你提供了最佳模型的特徵清單，但沒有提供實際迴歸係數數值。因此，以下針對常見的係數方向與變數意義進行解釋；正式報告應以你所訓練的 14 特徵模型係數表核對方向與數值，不宜將以下方向直接當作已確認的實驗結果。

（1）居住面積 `sqft_living`

一般預期係數為正，代表在其他條件相同時，居住面積越大，預測房價通常越高。居住面積是衡量房屋使用空間的重要指標，較大的房屋通常能提供更多生活空間，因此具有合理的正向關係。

但本資料同時包含 `sqft_above`、`sqft_living15` 等相關變數，所以 `sqft_living` 的係數代表的是控制其他空間變數後的額外關係，而不是單純比較兩間房屋的總面積差異。

（2）緯度 `lat`

若模型係數為正，表示在其他特徵固定時，緯度較高的房屋具有較高的預測價格；若係數為負，則方向相反。

緯度與房價的關係主要反映地理位置、社區特性及區域需求，而不是緯度本身直接創造房屋價值。因此，緯度係數應解讀為地理位置的代理指標。

（3）景觀 `view`

`view` 用於描述房屋的景觀評分。若係數為正，表示在控制其他條件後，較好的景觀評分通常與較高的預測房價相關。

這可能反映景觀帶來的居住吸引力與市場偏好。不過，景觀評分與房屋位置、建築品質可能有關，因此不能只依此係數就斷言景觀是房價差異的唯一原因。

（4）建築品質 `grade`

若 `grade` 的係數為正，代表較高的建築品質評分與較高的預測房價相關。建築品質可能反映建材、施工品質、設計及整體建築等級，因此是具有實務意義的預測特徵。

（5）水岸 `waterfront`

`waterfront` 通常是二元變數，用來表示房屋是否具有水岸條件。若其係數為正，代表在其他變數相同時，水岸房屋的預測價格較高。

由於水岸房屋可能具有稀有性、景觀優勢與特殊地段價值，模型可能估計出較高的價格差異。但此差異仍是控制其他特徵後的統計關聯，不代表單一條件必然造成固定幅度的價格上升。

（6）屋齡與建造年份 `yr_built`

`yr_built` 記錄房屋建造年份，而不是直接記錄屋齡。如果係數為正，代表在其他特徵固定時，較新的建造年份與較高的預測價格相關，這可能反映建築設備、設計與結構較新等因素。

不過，房屋翻修情形也會影響價格，因此模型同時保留 `yr_renovated`。此外，老屋可能具有特殊地段或歷史價值，所以不能推論所有老屋都一定比較便宜。

（7）為什麼不能直接解釋 `zipcode` 的係數？

本研究將 `zipcode` 當成數值型變數輸入 OLS。郵遞區號本質上是地理區域的識別碼，並不具有自然的連續尺度。

假設模型係數為負，也不能解釋成「郵遞區號每增加 1，房價就下降固定金額」。因為郵遞區號相差 1，不代表地理距離相同，也不代表房價應有固定方向的變化。

這是目前模型的重要限制。若將 `zipcode` 改為類別變數，模型可以比較不同郵遞區號區域相對於基準區域的價格差異，但也會增加模型欄位數量。因此，本研究的 `zipcode` 係數應視為一項簡化處理，而不是具有直接經濟意義的連續效果。

---

5. 五大回歸假設：哪些通過、哪些沒有通過？

線性回歸的評估不能只看 R^2，也需要檢查模型假設是否合理。依據本研究提供的診斷數值，可以初步整理如下。

假設或診斷項目	本次結果	判讀
線性關係	尚未提供完整診斷數值	無法確認完全成立
誤差獨立性	Durbin–Watson = 2.010	未見明顯的一階自相關訊號
同質變異性	$\lvert$殘差$\rvert$ 與配適值相關 = 0.496	顯示可能存在異質變異
殘差常態性	殘差偏態 = 3.540	明顯右偏，不符合對稱常態的特徵
無嚴重多重共線性	最大 VIF = 7.854	存在一定程度的共線性疑慮，需進一步判斷

（1）線性關係

多元線性回歸假設目標變數與輸入特徵之間的關係，能夠由線性組合合理描述。

目前沒有提供殘差與配適值圖、部分殘差圖或其他線性診斷結果，因此不能直接判定此假設通過。若殘差圖呈現彎曲、U 形或其他系統性規律，代表模型可能未充分描述變數之間的關係。

（2）誤差獨立性

Durbin–Watson 統計量為 2.010，接近 2，通常代表沒有明顯的一階殘差自相關。

因此，從這項指標來看，未觀察到強烈的一階自相關訊號。不過，Durbin–Watson 主要用於檢查特定形式的殘差自相關，不能單獨證明所有誤差都完全獨立。由於房屋交易具有地理位置與時間上的群聚性，仍可能存在未被此指標捕捉的空間或群聚相關。

（3）同質變異性

本研究中，絕對殘差與配適值的相關係數為 0.496，顯示預測房價增加時，殘差的絕對大小可能也傾向增加。

這與同質變異性的理想情況不一致，可能代表模型存在異質變異，也就是不同價格範圍的預測誤差分散程度不同。

這項結果是異質變異的警訊，但相關係數本身不是正式的異質變異檢定，最好搭配殘差圖或 Breusch–Pagan 檢定確認。

（4）殘差常態性

殘差偏態為 3.540，代表殘差分布明顯右偏，可能存在少數正向幅度很大的殘差，也就是模型對某些房屋的實際價格低估很多。

這與常態分布的對稱特徵不符，因此不能認為殘差常態性已經成立。

不過，殘差不常態並不代表 OLS 的係數估計一定無效。它主要影響傳統小樣本推論中信賴區間與假設檢定的可靠性，並可能與極端房價及模型未捕捉的非線性關係有關。

（5）多重共線性

最大 VIF 為 7.854，表示至少一個特徵可以由其他特徵相當程度地解釋。

VIF 的判斷門檻並非絕對：有些分析採用 5 作為需要注意的參考值，有些則以 10 作為較嚴重的警戒值。因此，7.854 比較適合解讀為存在值得注意的共線性，而不是直接宣告模型失敗。

在本資料中，居住面積、地上樓層面積、地下室面積與鄰近房屋面積之間可能存在資訊重疊。這種共線性會使個別係數較不穩定、標準誤可能增加，但不一定會明顯降低整體預測能力，也能解釋為什麼 RidgeCV 與 OLS 的測試 R^2 都是 0.6950。

殘差右偏與異質變異對預測區間的影響

本研究的高價房屋容易被低估，且少數低價房屋的預測值可能略低於 0。這反映線性模型在極端價格區域的限制。

傳統 OLS 的預測區間通常假設誤差結構合理，若殘差明顯右偏、變異程度又隨預測價格改變，區間可能無法在所有價格範圍維持理想的 95% 覆蓋率。

因此，報告中的 95% 預測區間應理解為**在模型假設下計算的估計範圍，而不是保證 95% 的實際房價一定會落在區間內**。尤其是高價房屋，可能需要更審慎地解讀預測結果。

---

6. 信賴區間與預測區間的差異：為什麼要畫在同一張圖？

信賴區間與預測區間雖然都可以呈現為預測線周圍的陰影帶，但兩者代表的統計意義不同。

（1）95% 平均數信賴區間

信賴區間用來描述在特定特徵條件下，模型估計的**平均房價**有多大的不確定性。

例如，對於具有相同指定特徵條件的一群房屋，模型會估計其平均價格。由於模型係數是從有限的訓練資料估計而來，因此這個平均價格並非完全確定，而是有一個估計範圍。

95% 信賴區間的涵義是：如果在相同條件下反覆抽樣、重新估計模型並建立區間，使用正確方法所建構的區間約有 95% 能涵蓋真正的平均反應。它不是指某一間新房屋有 95% 機率落在該區間內。

（2）95% 預測區間

預測區間用來描述**單一新房屋的實際價格**可能落在哪個範圍。

除了模型估計平均房價的不確定性之外，個別房屋本身也存在無法由現有特徵完全解釋的差異，例如裝潢品質、屋況細節、交易條件與其他未觀測因素。

因此，預測區間同時考慮平均估計的不確定性與個別觀測值的誤差，通常會比平均數信賴區間寬。

比較項目	平均數信賴區間	預測區間
估計對象	條件下的平均房價	單一新房屋的實際價格
是否考慮個別房屋的隨機誤差	不直接包含個別誤差	包含
區間寬度	通常較窄	通常較寬
實際用途	了解平均趨勢估計的不確定性	了解個別房價預測可能的誤差範圍

（3）為什麼把兩種區間畫在同一張圖？

將兩種區間畫在同一張預測圖上，可以清楚呈現兩種不同層次的不確定性。

- 中間的預測線呈現模型估計的平均價格趨勢。
- 較窄的 95% 信賴區間顯示平均趨勢估計的精確程度。
- 較寬的 95% 預測區間則呈現單一新房屋價格可能的波動範圍。

這種呈現方式能讓讀者理解，即使模型對平均房價的估計相對精確，個別房屋的實際交易價格仍可能有很大的差異。

對本研究而言，高價房屋被低估且殘差具有右偏與異質變異的現象，更凸顯了預測區間的重要性。它可以提醒使用者，房價預測不是單一確定答案，而是必須搭配誤差範圍一起解讀。

---

7. 為什麼其他研究使用 log(price)、類別型 zipcode 或樹模型時，R^2 常常更高？本研究為什麼仍採用 OLS？

King County 房價資料集是常見的回歸練習資料，因此網路上可以看到不同的前處理方式與模型。常見做法包括對房價取對數、將郵遞區號轉成類別變數，以及使用 Random Forest 或 Gradient Boosting 等非線性模型。

這些方法可能提高預測表現，但必須注意：**不同目標尺度、不同資料切分或不同前處理方式下得到的 R^2，不一定能直接公平比較。**

（1）使用 `log(price)`：降低極端高價房屋的影響

本資料的房價從 75,000 到 7,700,000，分布範圍相當大，而且殘差呈現明顯右偏。這代表少數高價房屋可能對平方誤差造成很大的影響。

將房價取自然對數後，模型改為預測：

$$\log(\text{price})$$

取對數可以壓縮高價與低價之間的尺度差距，讓模型更容易描述相對比例上的變化。例如，價格從 200,000 增加到 300,000，與從 2,000,000 增加到 2,100,000，雖然絕對差額都是 100,000，但其相對增幅並不相同。對數尺度能更自然地描述某些比例型關係。

此外，取對數有機會減少殘差右偏及異質變異的程度，因此可能改善模型假設與預測表現。

但取對數後的模型預測的是對數房價，不是原始房價。若要轉換回金額尺度，不能只把對數預測值當成原始價格；簡單使用指數函數還可能產生回轉偏差，需要適當的校正方法。

同時，對數模型的 R^2 是在對數房價尺度上計算，不能直接與原始房價模型的 R^2 當成完全相同的衡量標準。

（2）將 `zipcode` 當成類別變數：更能反映地區差異

郵遞區號是地區識別碼，不是真正的連續數值。若直接將它作為數值變數，OLS 會假設郵遞區號與房價之間存在單一線性關係，這個假設可能不符合真實的地理價格結構。

若將 `zipcode` 轉成類別變數，模型便能為不同地區估計相對於基準區域的價格差異，而不必假設郵遞區號數字增加時，房價會依固定方向改變。

這種做法可能提升模型表現，因為房價受到區域需求、生活機能、學區、交通與社區環境等因素影響，而這些資訊可能無法單靠 `lat` 與 `long` 的線性係數完整描述。

不過，將郵遞區號轉為類別變數會增加模型參數，也可能讓模型更容易記住訓練資料中特定地區的價格模式。因此，仍需使用適當的測試集或交叉驗證，確認效能改善能否泛化到新資料。

（3）使用 Random Forest 或 Gradient Boosting：捕捉非線性與特徵交互作用

OLS 的主要限制是預測值由輸入特徵的線性組合構成。即使有多個特徵，模型仍不會自動學習所有複雜的非線性關係。

例如，房屋面積增加帶來的價格變化，可能因地段、建築品質或景觀不同而有所差異；水岸條件的價值，也可能依區域而不同。

Random Forest 透過多棵決策樹的集成預測，能夠捕捉較複雜的非線性關係。Gradient Boosting 則逐步建立新的模型來改善先前的預測誤差，通常也能有效描述特徵之間的非線性關係與交互作用。

因此，這類模型在房價這種受多項因素影響、關係可能相當複雜的資料上，常有機會取得比基礎 OLS 更好的預測表現。

但較高的 R^2 不代表模型一定更適合所有研究目的。樹模型通常不會像 OLS 一樣，直接提供容易解讀的單一線性迴歸係數；若要說明模型如何作出預測，通常還需要搭配特徵重要性、部分依賴圖或 SHAP 等解釋方法。

（4）為什麼本研究仍以可解釋的 OLS 作為主要結果？

本研究的目標不只是追求最高的 R^2，也包括理解特徵選擇、分析係數方向、檢查回歸假設，以及呈現信賴區間和預測區間。

因此，OLS 有幾項優點：

1. **係數容易解釋：** 可以分析在其他特徵固定時，各特徵與預測房價的線性關聯。
2. **符合課程主題：** 直接對應多元線性回歸的模型建立、特徵選擇及模型評估要求。
3. **方便進行統計診斷：** 可以檢查殘差分布、異質變異、共線性及模型假設。
4. **適合比較特徵選擇：** 可以直接比較 18 個特徵與 14 個特徵模型，觀察精簡特徵是否仍保有相近的預測能力。
5. **容易建立統計區間：** 在適當假設下，可以計算平均反應的信賴區間與個別觀測值的預測區間。

本研究結果顯示，Forward SFS 選出的 14 特徵模型，測試 R^2 從 0.6950 微幅提升至 0.6954，RMSE 也略為降低；RidgeCV 的測試 R^2 則與完整 OLS 相同，都是 0.6950。

這表示在目前的資料切分與實驗設定下，精簡特徵可以維持相近的預測表現，而加入 Ridge 正則化並未在這次測試中帶來明顯的 R^2 提升。這不代表其他模型一定沒有優勢，而是說明在本次作業的研究目標下，OLS 已能提供可用的基準結果，並兼顧預測能力與可解釋性。

總結而言，OLS 是本研究的主要分析模型，而不是宣稱它是所有房價預測方法中準確率最高的模型。 若未來研究目標改為盡可能提高預測效能，可以再將 `log(price)`、類別型 `zipcode`、Random Forest 與 Gradient Boosting 納入比較，並在相同的資料切分、評估尺度與驗證流程下進行公平評估。

2026/10/14 下午8:53:33 · gpt-6